

Dirk Laschat

Systemisches Risiko im europäischen Bankensystem

Masterarbeit

im Fach Volkswirtschaftslehre

am Lehrstuhl für Volkswirtschaftslehre, insb. Monetäre Ökonomie
(Westfälische Wilhelms-Universität, Münster)

Themensteller: Prof. Dr. Martin Bohl

Betreuer: Alexander Pütz, M. Sc.

Ausgabetermin: 1. Juli 2020

Abgabetermin: 7. Oktober 2020

Vorgelegt von: Dirk Laschat

geb. am 16.12.1993

Bismarckallee 49

48151 Münster

Tel.: +49 179 5999033

dirklaschat@web.de

Volkswirtschaftslehre,

10. Semester,

Matrikelnummer: 430765

Inhaltsverzeichnis

I. Abbildungsverzeichnis.....	3
II. Tabellenverzeichnis	3
1. Einleitung.....	4
2. Literaturüberblick	5
2.1 Hintergrundinformationen zum systemischen Risiko	5
2.2 Messung von systemischen Risiken	6
3. Empirische Methodik.....	10
3.1 Quantilregressionen	10
3.2 Lasso-Verfahren	12
3.3 Das Modell	16
4. Daten	19
5. Ergebnisse	28
III. Literaturverzeichnis.....	52

I. Abbildungsverzeichnis

Abbildung 1: Stilisierte Quantilregression.....	11
Abbildung 2: Kapitalmarktrenditen, VaR und CoVaR der Deutschen Bank	28
Abbildung 3: Gesamtvernetzung & Durchschnitts-Lambda im europäischen Finanzsystem	29
Abbildung 4: Eingehende Effekte nach Ländergruppe.....	31
Abbildung 5: Ausgehende Effekte nach Ländergruppe.....	32
Abbildung 6: Ausgehende Effekte europäische Peripherie vs. Kerneuropa.....	33
Abbildung 7: Netzwerkplot zum 15. September 2008.....	34
Abbildung 8: Netzwerkplot zum 10. Juni 2011	34
Abbildung 9: Netzwerkplot zum 20. Mai 2016	35
Abbildung 10: Reduzierter Netzwerkplot zum 15. September 2008.....	38
Abbildung 11: Reduzierter Netzwerkplot zum 10. Juni 2011	38
Abbildung 12: Reduzierter Netzwerkplot zum 20. Mai 2016.....	39

II. Tabellenverzeichnis

Tabelle 1: Ausgewählte europäische Finanzinstitute nach Höhe der Aktiva.....	20
Tabelle 2: Mittel und Standardabweichung der Makrovariablen	26
Tabelle 3: Deskriptive Statistik der Renditen und institutsspezifischen Variablen	27
Tabelle 4: Anzahl eingehender und ausgehender Effekte nach Institut und Ländergruppe....	37
Tabelle 5: Auflistung der drei stärksten eingehenden und ausgehenden Effekte pro Institut.	41
Tabelle 6: Auflistung der 10 stärksten Effekte auf Einzelinstitutsebene	42
Tabelle 7: Top 10 Institute nach der Summe eingehender Effekte	44
Tabelle 8: Top 10 Institute nach der Summe ausgehender Effekte.....	44
Tabelle 9: Top 10 Institute nach dem Index der systemischen Risiko Empfänger	46
Tabelle 10: Top 10 Institute nach dem Index der systemischen Risiko Sender.....	46
Tabelle 11: Ergebnisse anderer systemischer Risikomaße.....	48

1. Einleitung

Die negativen Auswirkungen von Bankenkrisen sind allgemein bekannt. Sie können sehr weitreichend sein und schränken zudem zukünftige Wachstumspotenziale von Volkswirtschaften stark ein. Studien der EZB zeigen, dass Bankenkrisen in europäischen Staaten im Schnitt eine Erhöhung des Schulden-BIP-Verhältnisses um 22 % und einen Rückgang der Produktionsleistung um 9 % zur Folge haben (Lo Duca et al. 2017). Daher ist es ein zentrales Anliegen der Wirtschaftspolitik die Finanzstabilität bestmöglich zu wahren. Dabei lag der Fokus in der Zeit vor der letzten Finanzkrise jedoch verstärkt auf Einzelinstitutsebene. Regulierungsbehörden versuchten das Risiko individueller Banken zu beschränken, indem deren Bilanzen genau beobachtet und so Einleger vor Verlusten geschützt wurden. Diese Perspektive resultierte vor allem aus dem traditionellen Verständnis des Gesamtrisikos eines Finanzmarktes, das als Summe der einzelnen Risiken angesehen wurde (Welfens und Kadiric 2018). Dabei wurde die Idee des systemischen Risikos bereits in den 1970er-Jahren durch Minsky vorgedacht, damals unter dem Begriff der finanziellen Instabilität (Minsky 1977). Die Regulierungsbehörden vernachlässigten diesen Ansatz jedoch für eine lange Zeit. Erst durch die fatalen Auswirkungen der Krise 2008 begann ein Umdenken. Die Institute erlitten enorme Verluste durch die enge Verknüpfung untereinander, die sich wie ein Dominoeffekt entweder direkt über Verträge und Adressenausfallrisiken oder indirekt über sinkende Preise und Liquiditätsspiralen ausbreiteten. Infolgedessen wurden in Europa Regulierungsmaße wie Kapitalpuffer für global und anderweitig systemrelevante Banken eingeführt. Systemrelevante Institute werden nun nach den Vorschriften der EBA identifiziert und mit besonderen Eigenkapitalvorschriften abhängig von der Höhe der Systemrelevanz reguliert (Europäische Union 2013, 2014).

Dabei bleibt jedoch offen, wie valide das verwendete Verfahren für die Identifizierung systemrelevanter Banken ist. Wählt die Methodik der EBA die richtigen Institute aus? Eine Frage, die sich vor allem aufgrund der nicht-öffentlichen Verfügbarkeit der Daten stellt. Außerdem besteht großes Interesse an der genauen Struktur des Netzes, das die europäischen Finanzinstitute untereinander bilden. Welche Institute bergen das größte systemische Risiko? Welche sind am stärksten miteinander verflochten und wie genau verbreitet sich ein Schock innerhalb dieses Netzwerkes? All dies sind Fragen, die in dieser Arbeit beantwortet werden sollen. Das systemische Risiko wird dabei durch die empirische Messung des CoVaRs der 36 größten europäischen Banken ermittelt. Der CoVaR stellt den Verlust eines Instituts dar, den dieses erleidet, wenn das gesamte System unter Stress steht. Zu dessen Messung werden öffentlich zugängliche institutsspezifische sowie makroökonomische Zeitreihen im Rahmen von Quantilregressionen mit gleichzeitiger Variablenauswahl verwendet. Über die Bestimmung der Höhe des Einflusses

anderer Institute auf den CoVaR eines Zielinstitutes können als Ergebnis Rankings der Institutionen nach Risiko-Emittenten und Risiko-Empfängern erstellt werden. Darüber hinaus können die Effekte zwischen jedem Paar einzelner Institute identifiziert werden, was die Darstellung des gesamten Netzwerkes möglich macht.

2. Literaturüberblick

2.1 Hintergrundinformationen zum systemischen Risiko

Wie zuvor erwähnt, war Minsky (1977) einer der ersten Vordenker des Konzepts systemischer Risiken. Mit seiner Finanzinstabilitätshypothese zeigt er auf, dass Finanzkrisen nicht die Folge von Fehlverhalten der Politik, sondern der inhärenten Instabilität des Finanzsystems sind. Diese entsteht in ökonomisch guten Zeiten durch erhöhte Kreditvergabe und einem folglich erhöhten Verschuldungsgrad. Dabei unterscheidet Minsky drei verschiedene Kreditnehmer, die das Verhalten von Akteuren am Kapitalmarkt widerspiegeln. Dazu zählen Hedger, die Zins und Tilgung aus ihren Investitionen refinanzieren können, Spekulanten, deren Investitionen zur Rückzahlung des Zinses ausreichen, die für die Tilgung jedoch einen neuen Kredit aufnehmen müssen und Ponzis, die Zins und Tilgung nur aus dem steigenden Preis des Vermögensgegenstandes zahlen können. Tritt ein Schock wie z. B. eine Vermögenspreiskorrektur ein, fallen Ponzis aus. Spekulanten können nun aufgrund von Kreditrationierung keine neuen Kredite aufnehmen und fallen somit ebenfalls aus. Das gesamte System gerät in eine Abwärtsspirale, sodass sogar Hedger keine Kredite mehr bekommen. Die große Gefahr solcher Abwärtsspiralen resultiert aus dem hohen Vernetzungsgrad dieser drei Gruppen im Finanzsystem. Der Schock und die externen Effekte aus dem Verhalten der Ponzis auf Spekulanten und Hedger breitet sich somit rasant im System aus. Borio (2004) greift diese Idee auf und gilt als einer der ersten Autoren, die politische Maßnahmen für diese Abwärtsspiralen sowie die in guten Zeiten entstehende Prozyklizität diskutieren.

Brunnermeier und Pedersen (2009) sowie Krishnamurthy (2010) beschreiben die Struktur der Abwärtsspirale noch einmal detaillierter: Sinken Vermögenspreise durch einen negativen Schock, verschlechtert dies die Bilanzen der Banken. In der Folge kommt es zu zwei Effekten, die die Wirkung dieses Schocks verstärken. Um einen konstanten Verschuldungsgrad beizubehalten, müssen betroffene Institute Vermögenswerte verkaufen. Dadurch sinken die Preise weiter, was wiederum die Bilanz zusätzlich verschlechtert. Gleichzeitig erhöht sich die Unsicherheit der Marktteilnehmer, die sich aus diesem Grunde vom Handel zurückziehen. Die nun sinkende Liquidität am Markt hat höhere Margen zur Folge und erhöht somit die angeforderten Standards an Kreditnehmer, wodurch wiederum weniger Volumen und sinkende Liquidität am

Markt entsteht. All dies kann zu Ausverkäufen seitens schwacher Kreditnehmer führen und somit negative externe Effekte auf alle anderen Institute verbreiten. Empirische Bestätigung für die Existenz dieser Effekte geben z. B. die Arbeiten von Adrian et al. (2014), Adrian und Shin (2010) und Gorton und Metrick (2012). Es ist somit offensichtlich, dass nicht nur die Größe eines Institutes, sondern ebenso seine Vernetzung und die daraus resultierenden Risiko-Spillover auf andere Institute, Systemrelevanz ausmachen. Aus diesem Grund wird zusätzlich zum Begriff des „too big to fail“ auch immer wieder der Begriff des „too connected to fail“ in Betracht gezogen.

2.2 Messung von systemischen Risiken

Die EBA gibt den nationalen Aufsichtsbehörden für die Messung des systemischen Risikos einen Scoring-Ansatz, der den Kriterien des Basler Ausschusses für Bankenaufsicht genau folgt, vor. Hierbei werden relevante Indikatoren verschiedener Kategorien von Banken mit Exposures über 200 Mrd. Euro gesammelt. Dazu gehören Werte zur Größe, Verflechtung, Ersetzbarkeit und Komplexität des Instituts. Aus den Einzelwerten wird in einem Folgeschritt über die Ermittlung von Mittelwerten mit vorgegebenen Gewichtungsfaktoren ein Gesamtscore berechnet. Die Systemrelevanz wird hier nach der Höhe des Gesamtscores in fünf Kategorien unterteilt. Dabei steigt die Menge an zu hinterlegendem Kernkapital, je höher das Institut eingeordnet wird (EBA 2016).

Da die Daten zur Berechnung des Scoring-Ansatzes nur den Regulierungsbehörden vorbehalten sind, ist dieses Verfahren intransparent und für die Öffentlichkeit nicht nachvollziehbar. Dasselbe gilt auch für die auf theoretischer Ebene entwickelten Modelle von Ansteckungseffekten und Netzwerken im Finanzsystem nach z. B. Allen und Gale (2000), Freixas et al. (2000) und Leitner (2005). Da sie auf bankinternen Daten zu Vermögenswerten und Verbindlichkeiten basieren, ist eine empirische Analyse analog dieser Modelle nur schwerlich möglich. Arbeiten, die auf solchen Modellen beruhen, können lediglich Teilmärkte und bestimmte Vermögensklassen untersuchen zu denen Daten zur Verfügung stehen¹. Sie können dementsprechend bloß als Hinweise auf systemisches Risiko gelten. Beim Einsatz von multivariaten Wahrscheinlichkeitsverteilungen, wie z. B. der Extremwerttheorie in Zhou (2009), stellt die Komplexität des Verfahrens ein Problem dar. Ohne Annahmen, die die Anwendbarkeit einschränken, ist eine Berechnung hier nur schwerlich möglich.

¹ Als Beispiele für die Kategorie dieser Arbeiten können für den deutschen Markt Upper und Worms (2004) und für den US-Markt Furfine (2003) betrachtet werden.

Einige Ansätze erfüllen jedoch die Ansprüche an ein uneingeschränktes, mit öffentlich zugänglichen Daten berechenbares Messverfahren. So verwenden z. B. Lehar (2005) und Huang et al. (2009) auf Ausfallwahrscheinlichkeiten basierende Modelle. Erstere Arbeit betrachtet dabei die Wahrscheinlichkeit einer bestimmten Anzahl gleichzeitiger Zahlungsunfähigkeiten im Bankensektor. Um diese zu bestimmen, wird der Wert der Aktiva eines Institutes genutzt, der wiederum über die Black-Scholes-Formel für Kaufoptionen auf das Eigenkapital des Institutes berechnet wird. Zweitere Arbeit betrachtet ein Maß für systemisches Risiko, das auf den individuellen Ausfallwahrscheinlichkeiten aus Credit Default Swaps basiert und dessen Determinanten anschließend über ein vektorautoregressives Modell bestimmt werden. Tarashev et al. (2009) entwickeln einen auf Spieltheorie basierten Ansatz, der zusätzlich Kapitalrichtlinien abhängig von der Systemrelevanz des Institutes formuliert und Segoviano Basurto und Goodhart (2009) stellen das Finanzsystem als Portfolio individueller Institute dar, wobei sie Credit Default Swaps nutzen, um deren Beitrag zum Stress des Gesamtsystems zu identifizieren.

Neuere Literatur legt den Fokus auf die Erfassung aller relevanten Spillover-Effekte zwischen Einzelinstituten, um die gesamte Vernetzung und somit Risikofaktoren des Bankensystems im Detail darstellen zu können. Dazu werden Methoden aus dem Machine Learning verwendet, um möglichst hohe Datenmengen untersuchen zu können ohne verfälschte Ergebnisse zu erhalten. Anschließend kann das gesamte System mithilfe von Netzwerktopologien grafisch dargestellt werden. Hierbei stechen vor allem zwei Ansätze hervor: Die Netzwerkanalyse mithilfe von korrelationsbasierten Messungen und die zweistufigen Quantilregressionen.

Im Bereich der Korrelationsmessungen wurde die Granger-Kausalität bereits zur Darstellung von Handelsnetzen in Adamic et al. (2009) verwendet und in Adamic et al. (2017) veröffentlicht. Billio et al. (2012) führen das Konzept im Rahmen der Messung von systemischen Risiken im Finanzsektor ein. Dabei ist eine Zeitreihe Granger-kausal für eine zweite Zeitreihe, falls vergangene Werte ersterer Zeitreihe Informationen enthalten, die dabei helfen die zweite Zeitreihe zu prognostizieren. Sind beide Zeitreihen gegenseitig Granger-kausal, besteht eine Feedback-Beziehung. Arbeiten von Danielsson et al. (2011), Battiston et al. (2012) oder Burschi et al. (2010) zeigen, dass Granger-Kausalitäten in Renditen als Proxy für Spillover-Effekte zwischen Marktteilnehmern angesehen werden können. Billio et al. (2012) betrachten lineare sowie nicht-lineare Granger-Kausalität und evaluieren das Ausmaß, die Anzahl an eingehenden sowie ausgehenden Verbindungen sowie die Nähe von Institutionen zueinander. Ihr Modell basiert jedoch auf der paarweisen Bestimmung der Granger-Kausalität und ist somit bivariat. Es können nur Zusammenhänge zwischen zwei einzelnen Instituten oder einem Institut und dem Gesamtsystem in der Berechnung berücksichtigt werden. Dadurch fehlt es an

Informationen über die Einflüsse weiterer Institute auf die Zeitreihe des Zielinstituts, was es deutlich erschwert die Stärke der Spillover-Effekte genau zu ermitteln und das gemessene Paar akkurat in das Netzwerk einzufügen.

Diese Schwächen sollen durch Messung von Netzwerken, die auf Teilen der Varianzzerlegung aus vektorautoregressiven Modellen basieren, ausgeglichen werden. Mittels Varianzzerlegung ist es möglich die Bedeutung bzw. den Beitrag der Verluste eines Institutes für ein zweites Institut oder das gesamte System zu bestimmen. Dabei können vektorautoregressive Modelle die Effekte von endogenen Einflüssen isolieren und eine beliebig hohe Anzahl an Variablen beinhalten, solange das System identifizierbar ist. Diebold und Yilmaz (2009, 2012, 2014, 2015) entwickeln in einer Reihe von Arbeiten einen Rahmen für diese Schätzungen, müssen die Anzahl betrachteter Institute jedoch auf einen kleinen Satz internationaler Banken limitieren, damit das VAR-System identifizierbar bleibt. Demirer et al. (2018) erweitern dieses Rahmenwerk mithilfe des Lasso-Verfahrens, das es ermöglicht irrelevante Variablen von der Schätzung auszuschließen. Dadurch sind sie in der Lage ihren Datensatz auf 96 öffentlich gehandelte internationale Banken zu erweitern. Ein großer Nachteil von korrelationsbasierten Messungen bleibt jedoch, dass sie nicht speziell die äußeren (linken) Enden der Verteilung untersuchen. Netzwerkeffekte im Finanzsektor unterscheiden sich in guten Zeiten allerdings signifikant von denen in schlechten Zeiten, was Verzerrungen in den Ergebnissen mit sich bringen könnte (Härdle et al. 2016).

Das Feld der zweistufigen Quantilregressionen beruht auf dem CoVaR-Konzept von Adrian und Brunnermeier (2016) und beinhaltet auch die in dieser Arbeit verwendete Methode. Während der Value-at-Risk das unbedingte Risiko eines Institutes misst und somit für die Messung von systemischen Risiken ungeeignet ist, quantifiziert der CoVaR das erhöhte Risiko einer Bank unter der Bedingung, dass eine andere Bank Verluste erleidet. Da in diesem Fall die Entwicklungen am äußeren (linken) Ende der Verteilung von Interesse sind, werden Quantilregressionen zur Schätzung verwendet. Dabei wird zuerst der VaR eines Instituts geschätzt und dieser auf die Verluste des gesamten Finanzsektors regressiert. Um zeitliche Variation in den CoVaRs zu erlauben, werden zudem verschiedene makroökonomischen Variablen in den Regressionen berücksichtigt. Das Modell der beiden Autoren ist allerdings bivariat. Dies bringt ähnliche Nachteile wie bei der Messung bivariater Granger-Kausalität mit sich, wodurch auch in dieser Arbeit relevante Risiko-Spillover-Effekte nicht betrachtet werden. Aus diesem Grund wurde das CoVaR-Konzept in der Folge mehrfach auf den multivariaten Fall erweitert. Darunter u. a. von Hautsch et al. (2015) und Härdle et al. (2016), deren Arbeiten es ermöglichen das gesamte System als Netzwerk darzustellen.

Hautsch et al. (2015) führen im Rahmen des CoVaR-Konzepts ein systemisches Risiko Beta ein, das den Beitrag eines jeden Finanzinstitutes zum Systemrisiko misst. Es stellt den direkten marginalen Effekt des VaRs eines Institutes auf den VaR des gesamten Systems dar. Der CoVaR hingegen entspricht dem marginalen Effekt, der auf den Renditen beruht und nur über die im Vorhinein geschätzten VaRs variiert. Aufgrund von Multikollinearität kann der CoVaR nicht mittels institutsspezifischen Variablen modelliert werden. Deshalb können institutsspezifische Faktoren für systemische Relevanz nur über die makroökonomischen Variablen einfließen. Der Ansatz von Hautsch et. (2015) kann diese institutsspezifischen Beiträge zum Systemrisiko jedoch direkt mittels institutsspezifischen Variablen aufnehmen. Aufgrund der hohen Anzahl an Regressionsvariablen wird auch hier das Lasso-Verfahren zur Auswahl der Variablen integriert. Betz et al. (2016) wenden dieses Framework auf den europäischen Finanzsektor an und erstellen neben einem auf den Kapitalmarktrenditen basierenden Netzwerk ein auf CDS-Renditen basierendes System, um das Länderrisiko detaillierter analysieren zu können. Zusätzlich lösen sie Probleme mit Restriktionen bezüglich Stichproben mit hoher Netzwerkdichte und kurzem Stichprobenzeitraum und beziehen den Vernetzungsgrad eines Institutes in der Vorperiode als Regressor ein.

Härdle et al. (2016) verwenden ebenfalls institutsspezifische Variablen und eine Erweiterung des Lasso-Verfahrens zur Variablenauswahl. Sie erweitern vorherige Ansätze, indem auch nicht-lineare Effekte über eine Kopplungsfunktion geschätzt werden. Um Korrelationen zu vermeiden, wird nicht auf die Systemrenditen regressiert, stattdessen werden die paarweisen Effekte zu zwei Indizes für Risiko-Empfänger und Risiko-Emittenten zusammengefasst. Zeitliche Variation der Risiko-Spillover wird hier durch Schätzung von rollenden Zeitfenstern erreicht. Dabei beschränkt sich der untersuchte Datensatz auf US-amerikanische Institute. Der in dieser Arbeit angewandte Ansatz soll sich bis auf wenige Unterschiede an die Prinzipien des Verfahrens von Härdle et al. halten und dessen Ergebnisse um die Messung des systemischen Risikos im europäischen Finanzsystem erweitern.²

Alternativ zum CoVaR-Konzept besteht die Möglichkeit der Messung von Kapitaldeckungslücken, wie z. B. in Acharya et al. (2017) oder Brownlees und Engle (2017). Diese Arbeiten bestimmen das Risiko eines Institutes oder bestimmter Aktiva eines Institutes bei Stress des Gesamtsystems und somit die Kehrseite verglichen zum CoVaR-Konzept. Aufgrund der verschiedenen Betrachtungsweisen messen Kapitaldeckungslücken und der CoVaR verschiedene

² Das Verfahren sowie die Gemeinsamkeiten und Unterschiede zu Härdle et al. (2016) werden in Abschnitt 3.3 im Detail erläutert.

Dimensionen des systemischen Risikos. Dabei besteht bei der Messung von Kapitaldeckungslücken jedoch die Gefahr der Unterschätzung des systemischen Risikos hochvernetzter Institute, da durch das Verfahren nicht alle Spillover-Effekte identifiziert werden können (Hautsch et al. 2015).

Abschließend trägt Literatur wie die von Bisias et al. (2012) oder Rodríguez-Moreno und Peña (2013) zur Entwicklung der obigen Messansätze bei. Ihre Arbeiten vergleichen eine Vielzahl an quantitativen Kennzahlen aus dem Finanz- und Managementbereich, die zur Messung systemischer Risiken beitragen können und erörtern deren Vor- und Nachteile. Dasselbe gilt für Literatur über Indikatoren für systemisches Risiko wie z. B. Giesecke und Kim (2011) sowie zu Frühwarnsystemen wie z. B. Koopman et al. (2011) und Schwaab et al. (2011).

3. Empirische Methodik

3.1 Quantilregressionen

In diesem Abschnitt sollen schrittweise die zur Schätzung des angewandten Modells notwendigen statistischen Verfahren erläutert werden, um ein volles Verständnis für die Funktionsweise des Modells zu gewährleisten.

Während im Standard-OLS-Fall der durchschnittliche Einfluss der unabhängigen Variablen auf die abhängige Variable betrachtet wird, sind im Falle der Tail-Risk-Messung jedoch besonders die Einflüsse der unabhängigen Variablen auf die niedrigsten Ausprägungen der abhängigen Variable interessant. Diese Betrachtung wird durch Quantilregressionen ermöglicht. Hierbei wird statt des Mittels ein bestimmtes vom Regressor abhängiges Quantil betrachtet. Oder anders ausgedrückt: Während im OLS-Fall der bedingte Mittelwert linear im Regressor ist

$$E(y|x) = x\beta_m, \quad (1)$$

ist im Fall der Quantilregressionen nun ein bedingtes Quantil linear im Regressor

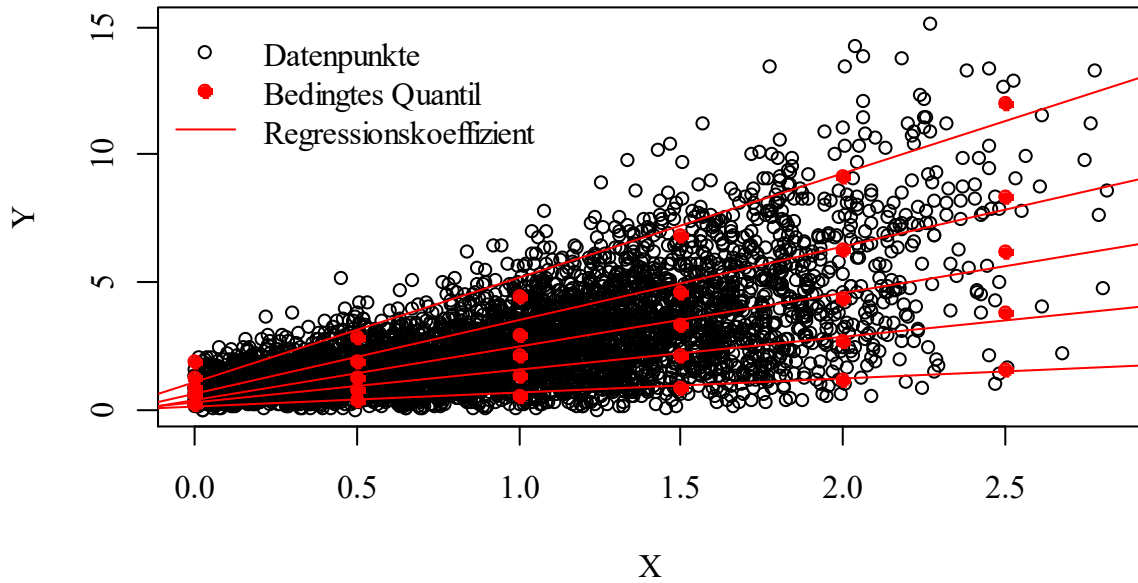
$$\mu_\tau(y|x) = x\beta_\tau, \quad (2)$$

$$\text{mit } \mu_\tau(y|x) = F_{y|x}^{-1}(\tau|x) = \mu_\tau(x).$$

Die oben beschriebene Situation soll durch Abbildung 1 veranschaulicht werden. Die rot eingefärbten Punkte stellen die Quantile einzelner Intervalle eines Regressors X dar. Um den quantilspezifischen Koeffizienten zu finden, wird eine spezielle Verlustfunktion mittels linearen Programmierens minimiert, wodurch die Koeffizienten der Regressionsgeraden erhalten werden. Wie deutlich zu erkennen ist, können die Zusammenhänge der Variablen je nach Quantil

stark variieren. Unterschiede wie in diesem künstlich erzeugten Ergebnis sind auch bei der Messung des Tail-Risks zu erwarten. So ist zu vermuten, dass Renditen in den untersten Quantilen deutlich stärker durch z. B. Liquiditäts- und Kreditausfallrisiken beeinflusst werden als Renditen in den obersten Quantilen.

Abbildung 1: Stilisierte Quantilregression



Um die gewünschten Koeffizienten zu erhalten werden zuerst die Quantile μ_τ für die Beobachtungen des Regressors benötigt. Koenker und Bassett (1978) stellen fest, dass das Stichprobenquantil als Lösung des Minimierungsproblems der folgenden Funktion nach $\widehat{\mu}_\tau$ dargestellt werden kann:

$$\min_{\widehat{\mu}_\tau \in \mathbb{R}} \left[\sum_{i: y_i \geq \widehat{\mu}_\tau} \tau |y_i - \widehat{\mu}_\tau| + \sum_{i: y_i < \widehat{\mu}_\tau} (1 - \tau) |y_i - \widehat{\mu}_\tau| \right]. \quad (3)$$

Dabei steht y_i für die einzelnen Beobachtungen der Stichprobe, $\widehat{\mu}_\tau$ als geschätzter Wert des Quantils und τ für das gesuchte Quantil. $|y_i - \widehat{\mu}_\tau|$ stellt somit den absoluten Schätzfehler dar, der mit den Gewichten τ und $(1 - \tau)$ multipliziert wird. Die Gleichung kann wie folgt interpretiert werden: Für den Fall des Medians ($\tau = 0,5$) sind die Gewichte für beide Teilterme gleich, was beim Abweichen der Beobachtung nach oben oder unten eine gleich harte „Bestrafung“ zur Folge hat. Sind die Gewichte jedoch verschieden, so wird positives bzw. negatives Abweichen unterschiedlich hart „bestraft“. Die Intuition hinter dieser Gewichtung kann am Beispiel des 0,75-Quantil leicht veranschaulicht werden: Hier liegen drei Viertel der Beobachtungen unterhalb des entsprechenden y-Wertes und ein Viertel oberhalb, somit ist das Unterschätzen dreimal so „kostspielig“ wie das Überschätzen und wird entsprechend stärker gewichtet, um den möglichst korrekten Wert des Quantils zu identifizieren.

Es ist nun möglich Gleichung (3) für den Fall linearer Regressionen zu erweitern. Dabei ist das Ziel den Erwartungswert des absoluten Schätzfehlers zu minimieren. Dies ist möglich, indem der für die Verlustfunktion optimale Schätzer $\widehat{\mu}_\tau(x) = x_i\beta_\tau$ eingesetzt wird. Es folgt die Gleichung

$$Q(\beta_\tau) = \sum_{i: y_i \geq x_i\beta_\tau} \tau |y_i - x_i\beta_\tau| + \sum_{i: y_i < x_i\beta_\tau} (1 - \tau) |y_i - x_i\beta_\tau|. \quad (4)$$

Diese Zielfunktion ist nicht differenzierbar und somit sind Gradienten-Optimierungsmethoden unangebracht. Es besteht jedoch die Möglichkeit die Koeffizienten β_τ mittels linearen Programmierens zu berechnen. Hierzu muss Gleichung (4) noch vereinfacht werden. Sie kann mithilfe einer Schlupfvariablen auch wie folgt geschrieben werden:

$$Q(\beta_\tau) = \sum_{i=1}^N [1_{\{y_i \geq x_i\beta_\tau\}} \tau (y_i - x_i\beta_\tau) + 1_{\{y_i < x_i\beta_\tau\}} (\tau - 1)(y_i - x_i\beta_\tau)]. \quad (5)$$

Durch Ausklammern des Schätzfehlers ergibt sich die folgende Gleichung

$$Q(\beta_\tau) = \sum_{i=1}^N \rho_\tau(y_i - x_i\beta_\tau), \quad (6)$$

mit: $\rho_\tau = \tau - 1_{\{y_i < x_i\beta_\tau\}}.$

Sie stellt die in der Literatur am weitesten verbreitete Notation für Quantilregressionen dar (Cameron und Trivedi 2005; Koenker 2005).

3.2 Lasso-Verfahren

Ein weiteres Problem der Tail-Risk-Schätzung ist die hohe Anzahl an Regressoren, die für die Beantwortung der Fragestellung verwendet werden muss. Dies kann die Interpretation des Modells aufgrund der schieren Menge an Variablen, sowie möglicher Scheinkorrelationen erschweren. Zusätzlich kann es bei Verwendung einer entsprechend hohen Zahl an zu untersuchenden Institutionen zu einer nicht ausreichend hohen Anzahl an Freiheitsgraden und somit Überidentifikation des Modells kommen. Um dies zu verhindern, wird das sogenannte Lasso-Verfahren verwendet. Ein Vorteil der Anwendung von OLS-Methoden ist zwar deren hohe Erwartungstreue, jedoch leidet die Schätzgenauigkeit oft aufgrund hoher Varianzen. Lasso kann dies verbessern, indem Koeffizienten mit geringem Einfluss auf null herabgesetzt werden. Dabei werden kleine Verzerrungen in Kauf genommen, um die Varianz und somit die Gesamtgenauigkeit zu erhöhen. Durch dieses Verfahren wird letztlich nur noch eine Teilmenge der stärksten Einflussfaktoren betrachtet und so auch die Interpretierbarkeit gesteigert (Tibshirani 1996).

Um Koeffizienten auf null herabzusetzen werden diese kontinuierlich verkleinert. Das Lasso-Verfahren verwendet für diesen Selektionsmechanismus ein sogenanntes „Tuning-Parameter“ (t), welches das Maß der Verkleinerung angibt. Je größer es ist, desto mehr Koeffizienten werden auf null herabgesetzt. Die Minimierung der Schätzfehler kann wie folgt dargestellt werden:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min \left\{ \sum_{i=1}^N (y_i - \alpha - \sum_j \beta_j x_{ij})^2 \right\} \text{ u.d.N. } \sum_j |\beta_j| \leq t \quad (7)$$

Für alle t gilt $\hat{\alpha} = \bar{y}$. Werden die Regressoren standardisiert ist $\bar{y} = 0$ und somit braucht α nicht berücksichtigt werden.

Für den Tuning-Parameter gilt $t \geq 0$. Er wird oft auch als L^1 -Strafe bezeichnet, da die L^1 -Norm, also die Summe der absoluten Werte, in der Nebenbedingung verwendet wird. Beträgt der Tuning-Parameter z. B. die Hälfte der L^1 -Norm $\sum_j |\hat{\beta}_j| / 2$, so würde die Lasso-Schätzung ca. die Hälfte, der im OLS-Fall geschätzten Koeffizienten erhalten. Alternativ kann das Minimierungsproblem auch wie folgt in Lagrange-Form geschrieben werden:

$$\mathcal{L}(y_i, x_{ij}, \lambda) = (y_i - x_{ij}\beta_j)^2 + \lambda \sum_j |\beta_j| \quad (8)$$

Hier wird der ursprüngliche Tuning-Parameter t als λ geschrieben. Es besteht eine 1-zu-1 Beziehung zwischen beiden Parametern, die abhängig vom Datensatz ist (Tibshirani 1996).

Die optimale Bestimmung der Parameter t bzw. λ ist somit essenziell für die Auswahl des korrekten Modells. Sie können jedoch nicht direkt aus den Daten berechnet werden, da $\lambda = 0$ den Fehler innerhalb der Stichprobe (in-sample-error) minimiert, dadurch eine OLS-Schätzung ausführen und die Modellqualität überschätzen würde. Eine Möglichkeit zur Schätzung des Tuning-Parameters ist z. B. das Kreuzvalidierungsverfahren. Hierbei wird die verwendete Stichprobe in zwei Teile segmentiert. Der erste Teil der Stichprobe dient der Anpassung der Regression, während der zweite Teil für die Messung des Schätzfehlers genutzt wird (Shao 1993).

Die im Lasso-Verfahren geschätzten Koeffizienten können dabei die sogenannte Orakel-Eigenschaft aufweisen. Die Orakel-Eigenschaft besagt, dass die asymptotische Verteilung des Lasso-Schätzers die gleiche ist wie die des Maximum-Likelihood-Schätzers auf den wahren Träger. Oder anders ausgedrückt: Die Lasso-Schätzer weisen die gleiche Präzision für die als relevant ausgewählten Regressoren auf wie das OLS-Verfahren, wenn an dieser Stelle nur die relevanten Regressoren verwendet werden (Zou 2006). Das hier bisher gezeigte Standard-Lasso-Verfahren kommt dabei sehr nah an diese Eigenschaft heran. Erweiterungen des Modells durch Modifizierung der L^1 -Norm können sie vollständig erreichen und werden im Folgenden im Rahmen von Quantilregressionen erläutert.

Wie OLS-Schätzer sind auch gewöhnliche Quantilregressionen bei einer hohen Anzahl an Regressoren inkonsistent, weshalb auch hier die Anwendung des Lasso-Verfahrens notwendig ist. So verwenden Hautsch et al. (2015) den Ansatz nach Belloni und Chernozhukov (2011), die zeigen, dass L^1 -Quantilregressionen der Orakel-Eigenschaft sehr nahekommen. Dazu wird eine Straffunktion, die zu Gleichung (6) eine Skalierung zur L^1 -Norm hinzufügt, verwendet:

$$\min_{\beta \in \mathbb{R}^p} \hat{Q}_\tau(\beta) + \frac{\lambda_n \sqrt{\tau(1-\tau)}}{n} \sum_{j=1}^p \hat{\sigma}_j |\beta_j|, \quad (9)$$

mit $\hat{\sigma}_j = \sum_{i=1}^n x_{ij}^2 / n$.

Die gesamte Strafe $\lambda \sqrt{\tau(1-\tau)}$ hängt somit vom individuellen Index des Quantils τ ab, während λ vom gesamten Satz der Quantile abhängt. Die Strafe sollte jedoch optimalerweise so ausfallen, dass irrelevante Regressoren/Koeffizienten hart genug bestraft werden, um sie auf null schrumpfen zu lassen, während relevante Regressoren/Koeffizienten nicht zu hart bestraft werden sollen, damit das korrekte Modell sowie die Orakel-Eigenschaft erreicht werden kann. Zheng et al. (2013) zeigen, dass durch Belloni und Chernozhukovs Ansatz genau Zweiteres geschieht. Da ihr Strafterm für jede Variable dieselbe Ordnung λ_n/n aufweist, bestraft er relevante Variablen zu hart. Die Autoren schlagen deshalb eine „Straffunktion“, die den obigen Vorgaben entspricht und somit robuste Koeffizienten mit Orakel-Eigenschaft liefert, vor. Die sogenannte adaptiv bestrafende Quantilregression

$$\hat{Q}_\tau(\beta) + \lambda_n \sum_{j=1}^p \omega_j |\beta_j|. \quad (10)$$

Sie weist verschiedenen Variablen sich anpassende Gewichte über den bekannten Gewichtsvektor ω_j zu. Ist dieser datenabhängig, kann gezeigt werden, dass bei korrekter Wahl die Orakel-Eigenschaft erreicht werden kann. Die Gewichte können z. B. aus einer ersten Lasso-Schätzung mit z. B. $\hat{\omega}_j = 1/|\hat{\beta}_j|$ bestimmt werden. Ist der Koeffizient sehr klein, so geht das Gewicht gegen unendlich, ist der Koeffizient hoch, geht das Gewicht gegen null.

Fan und Li (2011) konnten diese Ergebnisse noch einmal verallgemeinern, indem sie eine Strafe entwickeln, die die Annahmen, unter denen es zur Wahl des perfekten Modells kommt, lockert. Statt eines festgelegten Terms für jeden Koeffizienten wird nun eine nicht-konvexe Straffunktion $p(\cdot)$ verwendet. Die Funktion kann über die Beobachtungen j variieren und von λ abhängen, wodurch eine erste Stufe zur Bestimmung der Gewichte entfällt. Die sogenannte SCAD-Strafe (Smoothly Clipped Absolute Deviation Penalty) hat die folgende Form:

$$\hat{Q}_u(\beta) + \lambda_n \sum_{j=1}^p p_\lambda |\beta_j| \quad \text{mit } p_\lambda(\beta_j) = \begin{cases} \lambda |\beta_j| & \text{für } |\beta_j| \leq \lambda; \\ -\left(\frac{|\beta_j|^2 - 2a\lambda |\beta_j| + \lambda^2}{2(a-1)} \right) & \text{für } \lambda < |\beta_j| \leq a\lambda; \\ \frac{(a+1)\lambda^2}{2} & \text{für } |\beta_j| > a\lambda \end{cases} \quad (11)$$

Die SCAD-Strafe entspricht quadratischen Splines, die am Punkt null singulär und sonst stetig differenzierbar sind, wobei die Ableitungen außerhalb des Intervalls $[-a\lambda, a\lambda]$ null ergeben. Dies hat zur Folge, dass bei der Lösung des Minimierungsproblems irrelevante Koeffizienten auf null herabgesetzt werden, relevante Koeffizienten unverändert bleiben und die restlichen Koeffizienten in Richtung null verkleinert werden. Das optimale Paar (a, λ) könnte mittels Kreuzvalidierungsmethoden gefunden werden. Da dieses Verfahren jedoch Ungenauigkeiten zur Folge hätte, schlagen die Autoren nach Messung des Bayes'schen Risikos $a = 3,7$ vor und zeigen in Simulationen, dass diese datenbasierende Methode die Performance nicht signifikant verändert. Zudem entwickeln sie einen Algorithmus, der eine effizientere Berechnung der Lasso-Quantilregression ermöglicht. Dabei wird die iterative Bestimmung der Parameter umgangen, indem gezeigt wird, dass der Algorithmus mit iterativer Berechnung auch in einem Schritt zur effizienten Lösung des Problems kommen kann. Dies ist der Fall, wenn für die zu bestimmenden Koeffizienten ein guter Initialwert angegeben wird. Diese Initialwerte können z. B. durch Schätzung des gesamten Modells, also einer Quantilregression ohne Lasso, gefunden werden, solange das Modell nicht überangepasst ist.

Diese Methode wird schlussendlich im Modell dieser Arbeit genutzt, das im nächsten Abschnitt formuliert wird. Für die Wahl des Parameters λ stehen alternativ zu verschiedenen Kreuzvalidierungsverfahren auch Bayes'sche Informationskriterien zur Verfügung. Das GCV-Verfahren (Generalized Cross Validation) ist unter den erstgenannten Verfahren die meistverwendete Variante, führt jedoch zu überidentifizierten Modellen, wenn die Stichprobengröße nicht ausreichend groß ist. Das Gleiche gilt für das bayes'sche Akaike-Informationskriterium, da gezeigt werden kann, dass die approximierte Log-Transformation des GVCs dem Akaike-Informationskriterium entspricht.³ Deshalb soll das Schwarz-Bayes-Informationskriterium (BIC) verwendet werden. Es gilt als konsistentes Informationskriterium zur Auswahl der relevanten Variablen, was bereits im Rahmen der SCAD-Methode gezeigt werden konnte (Wang et al. 2007).

³ Für darüber hinausgehende Details s. Shao (1997), McQuarrie und Tsai (1998), Yang (2005).

3.3 Das Modell

In diesem Abschnitt werden Hintergründe sowie der genaue Aufbau des Modells geschildert. Das hier dargestellte Verfahren basiert mit einzelnen kleineren Unterschieden auf dem Verfahren von Härdle et al. (2016) und kann in vier Schritte unterteilt werden: Das Grundkonzept, die Schätzung der institutsspezifischen Value-at-Risks (VaRs), die Schätzung der institutsspezifischen CoVaRs und die abschließende Netzwerkanalyse.

Das Grundkonzept basiert auf der Messung der VaRs der Finanzinstitute. Der VaR kann für ein Institut i als

$$P(X_{i,t} \leq VaR_{i,t,\tau}) \equiv \tau \quad (12)$$

definiert werden. Dabei steht τ für das untersuchte Quantil mit $\tau \in (0,1)$ und $X_{i,t}$ für die logarithmierten Renditen des Institutes i zum Zeitpunkt t . Der $VaR_{i,t,\tau}$ misst somit die Höhe der Verluste, die mit $1 - \tau$ Wahrscheinlichkeit nicht überschritten wird (Hartmann-Wendels et al. 2019). Dies stellt nur eine isolierte Beobachtung des Risikos eines Einzelinstitutes dar. Für die Messung des systemischen Risikos sind negative Risiko-Spillover zwischen Instituten und somit deren Verbindungen untereinander relevant. Der von Adrian und Brunnermeier (2016) eingeführte CoVaR bezieht genau diese Verbindungen ein. Er ist für ein Finanzinstitut j zum Zeitpunkt t und das Quantil $\tau \in (0,1)$ definiert als

$$P\{X_{j,t} | C(R_{i,t}) \leq CoVaR_{j|C(R_{i,t}),t,\tau}\} \equiv \tau. \quad (13)$$

Hierbei wird die Höhe der Verluste des Institutes j zum Quantil τ berechnet, die es erzielt, wenn ein bestimmtes Ereignis C beim Institut i eingetreten ist. Typischerweise wird für das Ereignis C der $VaR_{i,t,\tau}$, also das Ereignis, dass die Verluste des Institutes i über oder genau auf Höhe des $VaR_{i,t,\tau}$ liegen, gewählt. $R_{i,t}$ stellt einen Satz an Informationen dar, der mit $X_{i,t} = VaR_{i,t,\tau}$ genau dieses Ereignis enthält. Zusätzlich enthält er einen Vektor von Makrovariablen M_{t-1} , die Auskunft über den Zustand der Volkswirtschaft geben. Die Makrovariablen sind dabei keine Indikatoren für systemisches Risiko, sie bestimmen vielmehr das Mittel und die Volatilität des zu schätzenden VaRs und CoVaRs durch ihren Einfluss auf die Renditen der Bank (Adrian und Brunnermeier 2016).

Die CoVaRs aller Institutionen werden mittels zweistufiger Quantilregression bestimmt. In einem ersten Schritt werden dazu die VaRs der Institute geschätzt. Hierfür werden die logarithmierten Renditen mittels Quantilregression auf die Makrovariablen regressiert. Mithilfe der

erhaltenen Koeffizienten, die die linearen Effekte zwischen beiden Variablen aufnehmen, kann im nächsten Schritt der VaR berechnet werden.

$$X_{i,t} = \alpha_i + \gamma_i M_{t-1}^L + \varepsilon_{i,t}, \quad (14)$$

$$\widehat{VaR}_{i,t,\tau} = \hat{\alpha}_i + \hat{\gamma}_i M_{t-1}^L. \quad (15)$$

Zu beachten ist, dass sich die den Instituten zugeordneten Makrovariablen variieren können. Da die Messung für europäische Finanzinstitute durchgeführt wird, müssen einzelne Makrovariablen länderspezifisch gemessen werden, weshalb der Satz an Makrovariablen vom Hauptsitz des Institutes abhängt ($M_{t-1}^L = M_{t-1}^{UK} \vee M_{t-1}^{DE} \vee M_{t-1}^{FR} \dots$). Des Weiteren ist der fehlende Zeitindex t für die Koeffizienten der obigen Gleichungen anzumerken. Da die Schätzung für ein festes Zeitfenster stattfindet, entfallen diese. Um alle Parameter für jeden Zeitpunkt zu erhalten, wird die Schätzung für ein 48-wöchiges rollendes Zeitfenster ausgeführt, was den Daten eines Kalenderjahres entspricht. Zudem werden die Makrovariablen hier sowie in den folgenden Regressionen standardisiert, wodurch eine Konstante in der Schätzung entfällt.

In der CoVaR-Schätzung wird, wie zuvor gezeigt, auf ein bestimmtes Ereignis konditioniert. Da eine multivariate Analyse durchgeführt werden soll, muss der Informationssatz somit die VaRs aller anderen Institutionen enthalten. Dabei konditioniert das hier zu schätzende Modell nicht nur auf die VaRs anderer Institute und die Makrovariablen, sondern fügt zusätzlich dazu noch institutsspezifische Variablen aus den Bilanzen der Bank als Kontrollvariablen hinzu. Dies ermöglicht es vor allem Risiko-Spillover, die durch Liquiditätsengpässe und andere Risiken entstehen, zu messen. Die Schätzung wird in den folgenden zwei Schritten durchgeführt:

$$X_{j,t} = \beta_{j|R_j}^T R_{j,t} + \varepsilon_{j,t} \quad (16)$$

$$\widehat{CoVaR}_{j|\tilde{R}_j,t,\tau} \equiv \hat{\beta}_{j|\tilde{R}_j}^T \tilde{R}_{j,t} \quad (17)$$

Zuerst wird der Informationssatz auf die logarithmierten Renditen des untersuchten Institutes regressiert, um die Koeffizienten zu erhalten. Dafür wird die im Abschnitt 3.2 gezeigte Quantil-Lasso-Regression nach Fan und Li (2011) verwendet, um nur relevante Variablen aus dem Informationssatz als Regressoren zu nutzen. Der Informationssatz ist dabei als $R_{j,t} \equiv \{X_{-j,t}, M_{t-1}^L, B_{j,t-1}\}$ definiert. $X_{-j,t}$ enthält alle logarithmierten Renditen außer der des Institutes j selbst. $B_{j,t-1}$ enthält die oben erwähnten institutsspezifischen Variablen aus der Bilanz der Bank j . Der Vektor aller Koeffizienten kann auch als $\beta_{j|R_j} = \{\beta_{j|-j}, \beta_{j|M}, \beta_{j|B_j}\}^T$ dargestellt werden. Im zweiten Schritt erfolgt wie auch bei der Berechnung des VaRs die Schätzung des

CoVaRs mithilfe der zuvor geschätzten Koeffizienten. Dabei werden im Informationssatz die VaRs aller anderen Institute statt der Renditen verwendet: $\tilde{R}_{j,t} \equiv \{\widehat{VaR}_{-j,t,\tau}, M_{t-1}^L, B_{j,t-1}\}$ und $\hat{\beta}_{j|R_j} = \{\hat{\beta}_{j|-j}, \hat{\beta}_{j|M}, \hat{\beta}_{j|B_j}\}^T$. Die Koeffizienten $\hat{\beta}_{j|-j}$ messen die Höhe der Spillover-Effekte zwischen einzelnen Finanzinstituten und stellen somit in ihrer Gesamtheit das Maß an Vernetzung im gesamten Finanzsystem dar. Im Gegensatz zu Härdle et al. (2016) wird in der Schätzung des CoVaRs keine Linkfunktion verwendet. Das hier verwendete Modell nimmt somit nur lineare Effekte auf. Der Hauptgrund eine Linkfunktion zu nutzen und nicht-lineare Effekte zu identifizieren, ist eine erhöhte Präzision, die vor allem für die Prognose zukünftiger systemischer Risiken wichtig ist. Da das Ziel dieser Arbeit eine Darstellung der systemischen Risiken sowie die Verifizierung der als systemrelevant eingeschätzten Institute im europäischen Finanzsystem ist, kann ohne Bedenken auf die Verwendung einer Linkfunktion verzichtet werden.

Nach erfolgreicher Schätzung der relevanten Variablen kann die Netzwerkanalyse durchgeführt werden. Hierbei können die Koeffizienten $\hat{\beta}_{j|-j}$ als $k \times k$ Netzwerkmatrizen N_F für alle geschätzten Fenster F zusammengefasst werden, wobei I_i für den Namen des Institutes i steht

$$N_F = \begin{matrix} & I_1 & I_2 & I_3 & \dots & I_k \\ \begin{matrix} I_1 \\ I_2 \\ I_3 \\ \vdots \\ I_k \end{matrix} & \begin{bmatrix} 0 & |\hat{\beta}_{1|2}^F| & |\hat{\beta}_{1|3}^F| & \dots & |\hat{\beta}_{1|k}^F| \\ |\hat{\beta}_{2|1}^F| & 0 & |\hat{\beta}_{2|3}^F| & \dots & |\hat{\beta}_{2|k}^F| \\ |\hat{\beta}_{3|1}^F| & |\hat{\beta}_{3|2}^F| & 0 & \dots & |\hat{\beta}_{3|k}^F| \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ |\hat{\beta}_{k|1}^F| & |\hat{\beta}_{k|2}^F| & |\hat{\beta}_{k|3}^F| & \dots & 0 \end{bmatrix} \end{matrix}. \quad (18)$$

Die Diagonale der Matrix enthält Nullen, da das Modell keine Einflüsse eines Institutes auf sich selbst berücksichtigt. Die Messung dieser Effekte ist nicht möglich, da die anhängige Variable nicht auf sich selbst regressiert werden kann. Betrachtet man in dieser strukturierten Darstellungsform den Satz an Koeffizienten $\hat{\beta}_{j|-j}$, sind alle vom Institut j ausgehenden Effekte in einer Spalte zu finden, während alle auf das Institut j eingehenden Effekte in einer Zeile zu finden sind. Somit können alle Informationen über die Vernetzung des gesamten Finanzsystems zu einem festen Zeitpunkt aus dieser Matrix ausgelesen werden.

Um das systemische Risiko einzelner Institute aus den Netzwerkmatrizen zu extrahieren, können die absoluten Effekte summiert werden, um ein Maß für Systemrelevanz zu erhalten. Da es die Datenstruktur erlaubt, werden die ein- und ausgehenden Effekte separat betrachtet, um erkenntlich zu machen welche Institute systemischem Risiko am meisten ausgesetzt und

welche am ehesten für es verantwortlich sind. Dazu werden wie folgt ein mit der Marktkapitalisierung gewichteter Index der Risikoempfänger (SRE) bzw. der Risikosender (SRS) gebildet:

$$SRE_j \equiv MK_{j,F} \left(\sum_{i \in k_F^{IN}} (|\hat{\beta}_{ji}^F| \cdot MK_{i,F}) \right) \quad (19)$$

$$SRS_j \equiv MK_{j,F} \left(\sum_{i \in k_F^{out}} (|\hat{\beta}_{ij}^F| \cdot MK_{i,F}) \right) \quad (20)$$

Hier stellen k_F^{IN} bzw. k_F^{out} den durch das Lasso-Verfahren identifizierten Satz an Instituten i dar, die mit Institut j im Fenster F durch eingehende bzw. ausgehende Effekte relevant miteinander verknüpft sind. $MK_{i,F}$ steht für die Marktkapitalisierung von Institut i zu Beginn des Fensters F . Um die Größe der Institute zu berücksichtigen, werden die einzelnen Effekte, die Institut j aufnimmt bzw. abgibt, zuerst mit der Marktkapitalisierung des Institutes von dem sie ausgehen bzw. auf das sie eingehen gewichtet. Die Summe dieser gewichteten Effekte wird dann mit der Marktkapitalisierung des Institutes j multipliziert. Der *SRE* summiert somit über die institutsspezifische Zeile der Netzwerkmatrix und der *SRS* über die entsprechende Spalte.

4. Daten

Für die Schätzung des Modells wird die Teilmenge europäischer Banken des Datensatzes von Demirer et al. (2018) gewählt. Die beiden Schweizer Banken UBS und Credit Suisse entfallen aufgrund fehlender Datenverfügbarkeit einzelner Makrovariablen. Tabelle 1 enthält die betrachteten 36 Banken aus 15 Ländern, geordnet nach deren Größe gemessen an der Aktivseite der Bilanz zum 31. Dezember 2013. Der Fokus liegt dabei auf der Periode von 2007 bis 2017, wodurch 519 wöchentliche Beobachtungen pro Variable generiert werden. Dabei sind alle im Folgenden beschriebenen Daten auf Datastream verfügbar. Die Stichprobe beinhaltet mit der belgischen Dexia, der spanischen Banco Popular Español, der finnischen Pohjola Pankki und der portugiesischen Banco Espirito Santo vier Institute, die den Markt verlassen mussten. Ihre Daten könnten jedoch wichtige Informationen für die Netzwerkanalyse enthalten, weshalb die Institute nicht komplett aus der Stichprobe entfernt, sondern ihre Renditen nach dem Marktaustritt auf null gesetzt werden. Somit ist gewährleistet, dass Effekte vor dem Marktaustritt dieser Institute mit in die Berechnung der Spillover-Effekte einfließen, während danach keine Effekte mehr von ihnen ausgehen.

Die Institute werden in sechs Ländergruppen aufgeteilt, um länderspezifische Spillover-Effekte in den Netzwerkplots leichter zu identifizieren. Dabei werden Frankreich, Belgien und die Niederlande als erste und Deutschland und Österreich als zweite Gruppe zusammengefasst. Zur Gruppe der britischen Finanzinstitute werden aufgrund der räumlichen Lage sowie der gemeinsamen Sprache die beiden irischen Banken hinzugefügt. Die National Bank of Greece wird

Tabelle 1: Ausgewählte europäische Finanzinstitute nach Höhe der Aktiva

Name	Land	Aktiva ¹⁾	MK ¹⁾	Kürzel	Gruppe
1. HSBC Holdings	UK	2.671	206,5	HSBA	UK
2. BNP Paribas	Frankreich	2.482	96,7	F:BNP	FR/BE/NL
3. Deutsche Bank	Deutschland	2.224	48,6	D:DBKX	DE/AUT
4. Barclays	UK	2.174	72,5	BARC	UK
5. Crédit Agricole	Frankreich	2.119	31,9	F:CRDA	FR/BE/NL
6. Société Générale	Frankreich	1.703	45,0	F:SGE	FR/BE/NL
7. Royal Bank of Scotland	UK	1.703	63,3	RBS	UK
8. Banco Santander	Spanien	1.538	101,2	E:SAN	SP/POR
9. ING Groep	Niederlande	1.490	53,2	H:INGA	FR/BE/NL
10. Lloyds Banking Group	UK	1.403	93,3	LLOY	UK
11. Unicredit	Italien	1.166	42,8	I:UCG	IT/GR
12. Nordea Bank	Schweden	870	54,1	W:NDAS	SKAND
13. Intesa Sanpaolo	Italien	864	40,5	I:ISP	IT/GR
14. BBVA	Spanien	803	71,3	E:BBVA	SP/POR
15. Commerzbank	Deutschland	759	18,3	D:CBKX	DE/AUT
16. Standard Chartered	UK	674	54,7	STAN	UK
17. Danske Bank	Dänemark	597	22,9	DK:DAB	SKAND
18. DNB ASA	Norwegen	396	29,1	N:DNB	SKAND
19. Svenska Handelsbanken	Schweden	388	31,2	W:SVK	SKAND
20. Skandinaviska Enskilda	Schweden	387	28,9	W:SEA	SKAND
21. KBC Groupe	Belgien	333	23,6	B:KB	FR/BE/NL
22. Dexia	Belgien	307	0,1	B:DEXB	FR/BE/NL
23. Swedbank	Schweden	284	30,9	W:SWED	SKAND
24. Erste Group Bank	Österreich	276	14,4	O:ERS	DE/AUT
25. Banca Monte dei Paschi	Italien	275	2,8	I:BMPS	IT/GR
26. Banco de Sabadell	Spanien	225	10,4	E:BSAB	SP/POR
27. Banco Popular Español	Spanien	204	11,4	E:POP	SP/POR
28. Bank of Ireland	Irland	182	11,2	BIRG	UK
29. Banco BPM	Italien	174	3,4	I:BP	IT/GR
30. Allied Irish Banks	Irland	162	80,2	A5G	UK
31. National Bank of Greece	Griechenland	153	12,7	G:ETE	IT/GR
32. Pohjola Bank	Finnland	132	6,4	M:POH	SKAND
33. Unipol Gruppo Finanziario	Italien	116	4,2	I:UNI	IT/GR
34. Banco Comercial Português	Portugal	113	4,5	P:BCP	SP/POR
35. Banco Espírito Santo	Portugal	111	5,7	@BKESF	SP/POR
36. Mediobanca	Italien	95	4,4	I:MB	IT/GR

¹⁾ Aktiva und Marktkapitalisierung zum 31.12.2013

mit den italienischen Banken als vierte Gruppe verbunden, da beide Länder eine große Rolle in der Staatsschuldenkrise spielten. Zuletzt werden noch Spanien und Portugal sowie die skandinavischen Länder jeweils in die beiden letzten Gruppen eingegliedert.

Die täglichen Kapitalmarktdaten sind über die in Tabelle 1 angegebenen Kürzel erhältlich und werden zu wöchentlichen logarithmierten Renditen transformiert. Für Makro- sowie institutspezifischen Variablen werden die europäischen Analoge eines jeden Landes zu den in der Literatur am meisten verwendeten und bewährten Variablen gewählt. Alle Makrovariablen liegen bereits in wöchentlicher Form vor und müssen nicht transformiert werden. Es werden dabei die folgenden sechs Variablen (EIKON Kürzel in Klammern) zur Charakterisierung der volkswirtschaftlichen Lage verwendet:

Kurzfristiges Liquiditätsrisiko:

Um das kurzfristige Liquiditätsrisiko abzubilden, wird der Spread zwischen dem 3-Monats EURIBOR (EIBOR3M) und dem EZB Hauptrefinanzierungssatz (EUROREF) berechnet. Ein steigender Spread zwischen Geldmarktzinsen gilt als Indikator für den Grad des Misstrauens zwischen Kreditinstituten. Zudem ist er das Steuerungsinstrument der EZB für die Geldpolitik, wobei ihr Ziel ist, den Spread möglichst gering zu halten. Es kann gezeigt werden, dass die Erhöhung von Spreads zwischen Zinssätzen der EZB und denen des Interbankengeschäfts durch wiederkehrende Liquiditätsdefizite von Finanzinstituten erklärt werden können. Dabei steigt der Interbankenzinssatz durch die tatsächlichen Liquiditätsdefizite sowie die steigende Unsicherheit über die generelle Liquiditätsausstattung des gesamten Finanzsektors. In der Folge wird die Refinanzierung für Banken deutlich teurer, die Margen fallen und Verluste entstehen (Linzert und Schmidt 2011).

Kreditrisiko:

Für das Kreditrisiko werden die Spreads von Credit-Default-Swaps auf 10-jährige Anleihen des Landes, in dem das Kreditinstitut seinen Hauptsitz hat, verwendet (z. B. DEGA\$AC für Deutschland). Mittels Credit-Default-Swaps kann sich ein Anleger gegen das Adressenausfallrisiko des Kontrahenten versichern. Dabei bestehen eine Vielzahl an Kanälen über die ein steigendes Ausfallrisiko des Heimatstaates direkten Einfluss auf die Verfügbarkeit sowie die Kosten der Refinanzierung ansässiger Finanzinstitute hat. So kann das eigene Risiko einer Bank steigen, wenn sie eine hohe Menge der im Risiko gestiegenen Staatsanleihe hält, da diese die Bilanz des Institutes verschlechtert. Staatsanleihen werden außerdem oft als Sicherheit in verschiedensten Geschäftsbereichen verwendet (z. B. in Repo-Geschäften, Absicherungen von OTC-Derivaten und Versicherungen von Pfandbriefen). Ein steigendes Ausfallrisiko des

Heimatstaates lässt hier Sicherheitsabschläge steigen, es könnte in der Folge zu Margin Calls aufgrund des sinkenden Wertes der Anleihen oder sogar dem Ausschluss als berechnigte Sicherheit kommen (Panetta 2011). Es besteht zudem ein direkter Einfluss zwischen dem Rating des Heimatstaates und dem der ansässigen Banken und falls Refinanzierungsgeschäfte nicht direkt abhängig von der eigenen Bonität des Instituts sind, werden stattdessen oft die Werte des Zentralstaates verwendet (Heinz und Sun 2014). Da der Spread genau den Kosten der Risikoübernahme entspricht und in der Regression alle Regressoren standardisiert werden, kann der absolute Spread des CDS als Höhe des Kreditrisikos der Volkswirtschaft angesehen werden.

Veränderung der Rendite auf 1-jährige Staatsanleihen:

In der Literatur werden an dieser Stelle für den Fall des US-Bankensektors dreimonatige Schatzanweisung gewählt. Nicht jeder der in dieser Arbeit relevanten europäischen Staaten gibt 3-monatige Staatsanleihen aus. Aus diesem Grund wurden 1-jährige Staatsanleihen gewählt (z. B. TRBDZ1Y für Deutschland), sie stellen die kurzfristigsten Anleihen mit Datenverfügbarkeit für die gesamte Stichprobe dar.

Die Renditen von kurzfristigen Staatsanleihen werden selbstverständlich stark durch das Kreditrisiko des emittierenden Staates beeinflusst, wodurch die vorher genannten Transmissionskanäle auch hier gültig sind. Für das Kreditrisiko wurden jedoch CDS auf langfristige Anleihen betrachtet. Um auch Effekte, die sich ggf. nur in kurzfristigen Anleihen widerspiegeln, ausweisen zu können, sollten auch diese betrachtet werden. Es kann gezeigt werden, dass ein nicht-linearer Zusammenhang zwischen den Renditen von Staatsanleihen und den Renditen von Banken besteht (Galvez und Mencia 2014). In Krisen wird dieser Zusammenhang sogar zu einem Feedbackmechanismus, der in der Literatur auch als „teuflische Schleife“ bekannt ist (Acharya et al. 2014).

Renditen der Immobilienwirtschaft:

Die Renditen der Immobilienwirtschaft werden über die Renditen des MSCI Europe Real Estate Indexes (M2URR2\$) approximiert. Dieser beinhaltet große und mittlere Unternehmen des Immobiliensektors aus 15 europäischen Industriestaaten. Sinken die Renditen im Immobiliensektor hat dies diverse Einflüsse auf den Zustand der Volkswirtschaft. So sind fallende Renditen von Immobilien im Finanzsektor mit Wertverlusten von Kreditsicherheiten verbunden. Reichen die Kreditsicherheiten nicht zur Deckung ausfallender Kredite aus, resultiert dies in Verlusten bei der kreditgebenden Bank. Außerdem wird im Investmentbanking zu großen Teilen in die Immobilienwirtschaft investiert, was wiederum direkten Einfluss auf die Profitabilität der Bank hat (Europäische Zentralbank 2000; Koetter und Poghosyan 2010).

Kapitalmarktrenditen:

Die Kapitalmarktrenditen werden durch die Renditen des STOXX Europe 600 (DJSTOXX) dargestellt. Dabei wird dieser dem EURO STOXX 50 vorgezogen, um einen möglichst breiten Blick auf den Kapitalmarkt zu gewährleisten. Dieser breite Aktienindex soll hier als Proxy für den Konjunkturzyklus dienen. Renditen der Finanzinstitute weisen eine besonders starke positive Korrelation mit dem Konjunkturzyklus auf, da eine positive Konjunkturentwicklung mit Investitionen und erhöhter Kreditaufnahme einhergeht. Banken können in diesen Zeiten somit höhere Gewinne erzielen. Dies gilt andersherum auch für Konjunkturabkühlungen. Auch Erträge aus dem Nicht-Zinsgeschäft werden durch die Konjunktur beeinflusst. So agieren viele Banken gleichzeitig als Broker, verkaufen Anteile an Publikumsfonds oder bieten andere Dienstleistungen gegen Gebühren an. Die hier erzielten Gewinne werden wie auch die Investitionen des Eigenhandels ebenfalls durch den Konjunkturzyklus beeinflusst (Albertazzi und Gambacorta 2009).

Volatilität des Kapitalmarktes:

Als Proxy für die Kapitalmarktvolatilität wird der VSTOXX Volatilitätsindex (VSTOXXI) gewählt. Er gilt als europäisches Pendant zum VIX der Chicago Board Options Exchange und misst das Risiko, dem Investoren ausgesetzt sind, über die implizierte Volatilität im Preis eines Korbes aus Call- und Put-Optionen auf den EURO STOXX 50 (Stoxx 2020). Die Volatilität bzw. die Erwartung über Volatilität kann als aktuelles bzw. zukünftiges Investmentrisiko angesehen werden. Empirische Studien geben Hinweise darauf, dass höhere Volatilität mit einer erhöhten Wahrscheinlichkeit für fallende Kapitalmärkte und eine niedrige Volatilität mit einer höheren Wahrscheinlichkeit für steigende Kapitalmärkte einhergeht (Li et al. 2005). Zudem beinhaltet die Volatilität wichtige Informationen für den gesamten Markt wie Liquidität, Inflation und auch sektorspezifische Faktoren.

Die institutsspezifischen Daten aus den Bilanzen der Banken liegen nur quartalsweise, in einzelnen Fällen und Zeiträumen nur halbjährlich, vor. Diese werden deshalb mittels kubischen Splines auf tägliche Daten interpoliert und in einem zweiten Schritt auf wöchentliche Frequenz aggregiert. Die institutsspezifischen Daten sollen Kontrollvariablen darstellen, um vor allem Risiko-Spillover, die durch Liquiditätsengpässe und andere Bankrisiken entstehen, zu erfassen. Als Kontrollvariablen werden die folgenden fünf Variablen gewählt:

Verschuldungsgrad:

Der Verschuldungsgrad wird durch die Division der Bilanzsumme (WC02999A) durch den Buchwert des gesamten Eigenkapitals (WC03501A) eines Institutes berechnet und kann als Indikator für Gläubigerausfallrisiken interpretiert werden. Je höher der Verschuldungsgrad ist, desto höher ist auch die Wahrscheinlichkeit, dass die Erträge der Bank nicht ausreichen, um Rückzahlungen an Fremdkapitalnehmer zu leisten. Außerdem wird der Anreiz verstärkt gläubigerschädigende Maßnahmen zu ergreifen, weshalb sich Banken mit höherem Verschuldungsgrad höheren Kapitalkosten ausgesetzt sehen. Da aufgrund regulatorischer Vorgaben Kapital für risikobehaftete Aktiva hinterlegt werden muss, haben die Kapitalkosten und durch diese auch der Verschuldungsgrad direkten Einfluss auf Renditeziele und somit die Allokation des Kapitals (Hartmann-Wendels et al. 2019).

Laufzeitinkongruenz:

Die Laufzeitinkongruenz wird als Quotient der Summe aus kurzfristigen und fälligen langfristigen Schulden (WC03051A) abzüglich liquider Mittel (WC02005A) und den Gesamtverbindlichkeiten (WC03351A) gebildet. Fristentransformation ist eine der Hauptfunktionen von Finanzinstituten. Über Laufzeiteninkongruenzen verdienen Banken ihre Nettozinsmargen, indem sie kurzfristige Kredite aufnehmen und zu höheren Zinsen langfristige Kredite vergeben. Jedoch kann sie auch nicht außer Acht zu lassende Liquiditäts-, Zinsänderungs- oder Währungsrisiken darstellen. Diese können schlagend werden, wenn Positionen nicht oder nur teilweise gehedgt sind oder nicht genügend Liquidität zu Verfügung steht, um fällige Verbindlichkeiten zu bedienen (Brunnermeier und Oehmke 2013; Farhi und Tirole 2012).

Kurs-Buchwert-Verhältnis:

Für das Kurs-Buchwert-Verhältnis wird die auf Datastream verfügbare Kennzahl WC09304A direkt übernommen. Es kann als Einschätzung der Marktteilnehmer über den Wert einer Firma angesehen werden und ist somit zukunftsorientiert. Im Feld der Banken kann das Kurs-Buch-Verhältnis stark von den Aktivitäten der Bank abhängen. Haben Institute ein besonders hohes Eigenhandelsvolumen und engagieren sich vermehrt in nicht traditionellen Geschäften, so entstehen vermehrt Risiken und Unsicherheiten, die Investoren in ihre Bewertung einbeziehen. Es kann gezeigt werden, dass höhere Kosten, niedrigere Erträge auf Aktiva, niedrigere Kernkapitalquoten und niedrigere nicht-verzinsliche Erträge mit niedrigeren Kurs-Buch-Verhältnissen einhergehen (Jordan et al. 2011). Das Kurs-Buch-Verhältnis spiegelt somit die Sorge der Investoren wider, dass die Bank unerkenntlichen Gesamtrisiken ausgesetzt ist und hat über diesen Kanal Auswirkungen auf die Renditen.

Größe:

Die Größe der Bank wird anhand des logarithmierten Buchwertes des Eigenkapitals (WC03501A) gemessen. Je größer eine Bank wird, desto mehr expandiert sie in nicht traditionelle Geschäfte, wodurch Risiken entstehen. Es kann empirisch nachgewiesen werden, dass die Volatilität und das Markt-Beta in der Größe einer Bank steigen (Elyasiani et al. 2020). In der Folge müssen mit diesen erhöhten Risiken auch höhere Renditen erzielt werden.

Volatilität der Eigenkapitalrendite:

Die Volatilität der Eigenkapitalrendite wird als 22-tägige, rollende Standardabweichung der täglichen Eigenkapitalrenditen der Banken berechnet und auf wöchentliche Frequenz aggregiert. Die Volatilität misst die Streuung der Eigenkapitalrenditen um deren Mittel und kann somit als Risikomaß interpretiert werden. Dabei kann die Volatilität positiv sowie negativ mit den Eigenkapitalrenditen korreliert sein. Langfristige Veränderungen der Volatilität sind dabei meist auf Veränderungen von Risikoprämien zurückzuführen, was eine positive Korrelation darstellt. Kurzfristige Veränderungen von Volatilität entstehen dagegen oft durch neue Informationen bezüglich des Instituts. Schlechte Neuigkeiten sind mit erhöhter Volatilität und negativen Renditen verbunden, was einer negativen Korrelation entspricht (Harvey und Lange 2018). Da hier nur der durchschnittliche Effekt von Interesse ist, sind die entgegengesetzten Wirkungen kein Problem, sodass keine Aufteilung der Effekte notwendig ist.

Die Tabellen 2 und 3 zeigen relevante deskriptive Statistiken der gewählten Variablen. Tabelle 2 für die Makrovariablen und Tabelle 3 für die Renditen sowie die institutsspezifischen Bilanzkennzahlen. Im Fall der Makrovariablen werden das Kreditrisiko sowie die Veränderung der Renditen von 1-jährigen Staatsanleihen länderspezifisch erhoben, während die restlichen Variablen auf europäischer Ebene ermittelt werden und somit für alle Länder identisch sind. Es wird der Mittelwert (M) und die Standardabweichung (SD) aufgelistet. Dabei sind im Falle des Kreditrisikos wie zu vermuten Nationen wie Griechenland, Irland, Italien, Spanien und Portugal mit hohen Durchschnittswerten und Streuungen auffällig. Die Veränderungen der Renditen 1-jähriger Staatsanleihen sind sich im Gegensatz dazu sehr ähnlich. Die durchschnittlichen wöchentlichen Veränderungen bewegen sich mit Werten zwischen -0,007 und -0,01 Prozent im leicht negativen Bereich. Lediglich griechische Anleihen weichen aufgrund der drohenden Zahlungsunfähigkeit im Jahr 2010 mit einem positiven Wert von 0,004 Prozent ab. Die durchschnittlichen wöchentlichen Renditen der Immobilienwirtschaft und des Euro STOXX 600 liegen im leicht negativen Bereich, was zeigt, dass sich die Märkte während des Stichprobenzeitraums noch nicht vollständig von der Krise erholt haben. Dabei werden die Turbulenzen am

Markt durch die hohe Standardabweichung beider Variablen widergespiegelt. Der VSTOXX streut dagegen weniger um sein Mittel, was ein Indikator für eine konstantere Einschätzung des Risikos durch die Marktteilnehmer ist. Das kurzfristige Liquiditätsrisiko hat zwar ein kleines Mittel, jedoch eine vergleichsweise hohe Standardabweichung. In Zeiten der Krise ist der Spread zwischen 3-Monats EURIBOR und dem EZB Hauptrefinanzierungssatz hoch, während die darauffolgende ultralockere Geldpolitik der EZB ihn zu späteren Zeitpunkten sogar negativ werden lässt.

Für die wöchentlichen Renditen der Institute werden zusätzlich zum Mittelwert und der Standardabweichung auch die Schiefe und Wölbung angegeben, um einen besseren Eindruck der Verteilung und ihrer Enden zu vermitteln. Ein negativer Wert für die Schiefe zeigt, dass sich am linken Ende der Verteilung mehr Daten als am rechten Ende befinden, während eine hohe Wölbung auf vermehrtes Auftreten von extremen Werten, also „dickere“ Enden hinweist. Besonders auffällig sind diese Werte z. B. bei der Royal Bank of Scotland und der Banco Espirito Santo. Auch Institute wie Barclays, Lloyds, KBC und die National Bank of Greece fallen mit extremeren Werten auf. Dies zeigt, dass die Renditen dieser Institute deutlich volatiler waren und die entsprechenden Institute im Falle einer höheren negativen Schiefe vergleichsweise höhere Verluste erlitten. Dementsprechend sind die Werte der entsprechenden Institute auch bei der Kennzahl Volatilität der Eigenkapitalrendite (VOL) der institutsspezifischen Kontrollvariablen auffällig. Beim Betrachten der restlichen Kontrollvariablen (Verschuldungsgrad (VG), Laufzeiteninkongruenz (LZIK), Kurs-Buchwert-Verhältnisses (P/B) und Größe) fallen bis auf den extremen Verschuldungsgrad der insolventen Dexia (70,2) keine besonderen Muster auf.

Tabelle 2: Mittel und Standardabweichung der Makrovariablen

Land	Kreditrisiko		Δ Staatsanleihe		Liqui.risiko		Immobilien		ESTOXX		VSTOXX	
	M	SD	M	SD	M	SD	M	SD	M	SD	M	SD
UK	60,1	30,6	-0,00010	0,0010	0,013	0,368	-0,002	0,041	-0,00003	0,029	25,07	9,33
Frankreich	80,9	56	-0,00009	0,0008								
Deutschland	46,8	29,7	-0,00009	0,0008								
Spanien	175,4	125,3	-0,00008	0,0021								
Italien	183,5	119,4	-0,00008	0,0018								
Niederlande	56,4	33,7	-0,00009	0,0009								
Schweden	46,1	24,3	-0,00009	0,0008								
Dänemark	44,8	34,6	-0,00009	0,0009								
Norwegen	29	10,8	-0,00007	0,0010								
Belgien	99	71,4	-0,00009	0,0011								
Österreich	74,4	51,7	-0,00009	0,0009								
Irland	209,9	194,7	-0,00008	0,0048								
Griechenland	396,2	238,8	0,00004	0,0468								
Finnland	42,9	21,1	-0,00008	0,0009								
Portugal	309,2	266,8	-0,00007	0,0051								

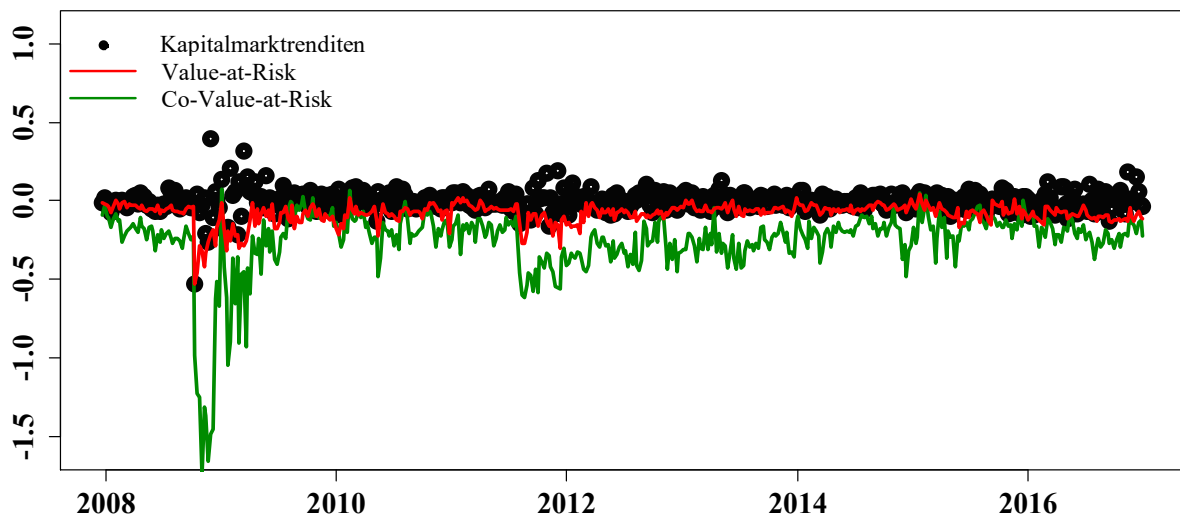
Tabelle 3: Deskriptive Statistik der Renditen und institutsspezifischen Variablen

Institute	Renditen				VG		LZIK		P/B		Größe		VOL	
	M	SD	Schiefte	Wölbung	M	SD	M	SD	M	SD	M	SD	M	SD
1. HSBC Holdings	0,000	0,040	-1,007	12,487	17,2	3,3	0,032	0,031	1,169	0,284	18,3	0,262	0,016	0,010
2. BNP Paribas	-0,001	0,061	-0,293	9,733	28,8	7,1	0,043	0,061	0,834	0,303	18,1	0,252	0,024	0,014
3. Deutsche Bank	-0,003	0,065	-0,430	15,535	40,3	12,8	0,088	0,065	0,677	0,270	17,7	0,258	0,024	0,015
4. Barclays	-0,002	0,088	-0,378	26,805	33,0	13,4	0,164	0,079	0,681	0,276	17,6	0,343	0,028	0,021
5. Crédit Agricole	-0,002	0,064	-0,228	5,869	36,0	4,9	0,082	0,031	0,561	0,212	17,6	0,104	0,026	0,014
6. Société Générale	-0,002	0,070	-0,344	5,624	26,6	4,2	0,072	0,041	0,661	0,351	17,6	0,212	0,027	0,015
7. Royal Bank of Scotland	-0,006	0,095	-4,097	51,834	22,3	7,4	0,097	0,064	0,561	0,208	18,0	0,166	0,031	0,029
8. Banco Santander	-0,001	0,054	-0,554	6,467	16,5	1,2	0,078	0,053	1,030	0,341	18,1	0,188	0,022	0,011
9. ING Groep	-0,001	0,074	-1,430	13,269	27,9	8,8	0,075	0,055	0,861	0,457	17,6	0,200	0,027	0,020
10. Lloyds Banking Group	-0,003	0,081	-1,234	25,262	23,8	7,3	0,054	0,085	1,062	0,407	17,3	0,571	0,027	0,023
11. Unicredit	-0,005	0,074	-1,005	8,634	17,0	2,2	0,135	0,044	0,628	0,364	17,8	0,151	0,029	0,015
12. Nordea Bank	0,000	0,044	-0,594	12,106	23,8	1,8	0,152	0,116	1,290	0,265	19,2	0,194	0,019	0,011
13. Intesa Sanpaolo	-0,002	0,059	-0,831	6,704	13,0	1,2	0,102	0,029	0,756	0,302	17,7	0,071	0,026	0,013
14. BBVA	-0,002	0,054	-0,527	5,480	16,3	2,4	0,155	0,022	1,206	0,509	17,4	0,245	0,021	0,010
15. Commerzbank	-0,006	0,074	-0,038	10,343	30,6	12,2	0,190	0,053	0,469	0,293	16,9	0,272	0,028	0,016
16. Standard Chartered	-0,001	0,056	-0,463	10,785	15,2	1,8	0,024	0,032	1,244	0,457	16,9	0,394	0,022	0,014
17. Danske Bank	0,000	0,054	-1,004	13,857	27,7	4,4	0,170	0,078	0,949	0,313	18,6	0,171	0,019	0,010
18. DNB ASA	0,001	0,055	-0,881	15,303	18,3	2,8	0,065	0,079	1,070	0,256	18,6	0,337	0,021	0,014
19. Svenska Handelsbanken	0,001	0,040	-0,364	7,230	25,0	2,4	0,103	0,162	1,564	0,246	18,4	0,214	0,017	0,010
20. Skandinaviska Enskilda	0,000	0,061	-0,827	11,961	23,6	3,8	0,101	0,118	1,265	0,381	18,5	0,203	0,022	0,016
21. KBC Groupe	-0,001	0,089	-1,372	16,011	21,6	15,5	0,066	0,048	1,224	1,336	16,5	0,323	0,030	0,022
22. Dexia	-0,014	0,118	0,335	9,284	70,2	107,6	0,272	0,073	0,511	0,664	15,4	0,738	0,058	0,059
23. Swedbank	0,000	0,059	-0,636	10,196	20,2	2,2	0,126	0,151	1,363	0,474	18,4	0,195	0,022	0,015
24. Erste Group Bank	-0,001	0,071	-0,968	12,358	19,4	2,6	0,090	0,047	0,955	0,397	16,2	0,146	0,027	0,015
25. Banca Monte dei Paschi	-0,012	0,081	-0,367	9,021	20,0	6,5	0,179	0,059	0,534	0,413	16,2	0,360	0,032	0,019
26. Banco de Sabadell	-0,003	0,054	0,495	4,278	16,5	1,5	0,147	0,057	0,916	0,450	15,8	0,410	0,020	0,008
27. Banco Popular Español	-0,007	0,064	-0,062	4,326	15,2	4,4	0,209	0,063	0,927	0,679	16,0	0,270	0,025	0,011
28. Bank of Ireland	-0,007	0,120	-0,453	10,233	20,4	6,0	0,074	0,096	0,862	0,545	15,9	0,142	0,042	0,033
29. Banco BPM	-0,007	0,078	-0,291	6,472	13,4	1,5	0,184	0,077	0,419	0,320	16,0	0,234	0,031	0,014
30. Allied Irish Banks	-0,013	0,132	-0,170	7,595	14,5	7,6	0,217	0,087	1,807	1,572	16,1	0,299	0,050	0,032
31. National Bank of Greece	-0,017	0,132	-1,621	14,741	8,2	16,5	0,206	0,062	0,995	1,068	15,8	0,156	0,047	0,028
32. Pohjola Bank	0,001	0,045	-0,332	9,606	16,3	1,3	0,113	0,149	1,241	0,190	14,7	0,256	0,016	0,014
33. Unipol Gruppo Finanziario	-0,005	0,062	-0,335	5,098	12,9	3,8	0,008	0,004	0,500	0,225	15,4	0,120	0,025	0,014
34. Banco Comercial Português	-0,008	0,069	-0,185	3,969	21,2	5,6	0,136	0,044	0,926	0,751	15,2	0,270	0,029	0,012
35. Banco Espírito Santo	-0,007	0,084	-7,621	118,044	14,3	2,1	0,176	0,059	0,717	0,407	15,5	0,175	0,020	0,020
36. Mediobanca	-0,002	0,051	-0,343	3,665	10,0	1,8	0,181	0,064	0,988	0,438	15,8	0,122	0,022	0,009

5. Ergebnisse

Die Berechnung der Regressionen wird mit $\tau = 0,05$, also zum 5 %-Quantil der Renditeverteilung, durchgeführt. Somit wird im Fall des VaRs eines Finanzinstitutes der Verlust in Kapitalmarktrenditen geschätzt, der mit 95 % Wahrscheinlichkeit nicht überschritten wird. Während in dieser Rechnung nur die fünf Makrovariablen als unabhängige Variablen genutzt werden, werden bei der Berechnung des CoVaRs $p = 46$ unabhängige Variablen verwendet (5 Makrovariablen, 6 institutsspezifische Kennzahlen aus der Bilanz der Bank und 35 Renditen der anderen Finanzinstitute). Abbildung 2 zeigt beispielhaft die Kapitalmarktrenditen, den VaR und den CoVaR der Deutschen Bank über den Verlauf der gesamten Stichprobe. Dabei ist deutlich zu erkennen wie der CoVaR zum Höhepunkt der Weltfinanzkrise, dem Zusammenbruch der amerikanischen Investmentbank Lehman Brothers, gegen Ende des Jahres 2008, stark ansteigt. Eine zweite Spitze lässt sich um das Jahr 2012 identifizieren, was in den Verlauf der europäischen Staatsschuldenkrise eingeordnet werden kann. Zu diesem Zeitpunkt sind die langfristigen Renditen vieler europäischer Staatsanleihen stark gestiegen, was den Zweifel der Gläubiger über ihre Kreditwürdigkeit widerspiegelte.

Abbildung 2: Kapitalmarktrenditen, VaR und CoVaR der Deutschen Bank



Die im Folgenden durchgeführte Netzwerkanalyse des europäischen Finanzsektors kann in 3 Stufen der Vernetzung aufgeteilt werden: 1. Die Analyse der Gesamtvernetzung des Systems, 2. Die Vernetzung auf Ebene der Ländergruppen und 3. Die Vernetzung auf Einzelinstituts-ebene. Im Anschluss sollen die erhaltenen Ergebnisse mit den Ergebnissen von alternativen Methoden zur Messung von systemischen Risiken verglichen werden, um ihre Validität zu überprüfen.


Die Gesamtvernetzung des Systems kann als Summe aller eingehenden bzw. ausgehenden Effekte

$$GV = GV^{IN} = GV^{OUT} = \sum_{i=1}^k \sum_{j=1}^k |\hat{\beta}_{j|i}^F|, \quad (21)$$

betrachtet werden. Dabei entspricht jeder ausgehende Effekt eines Institutes auch einem eingehenden Effekt bei einem anderen Institut. Als zweites Maß können die Lambdas des Lasso-Verfahrens aus den CoVaR-Schätzungen ausgewertet werden. Berechnet man deren durchschnittlichen Wert über alle Institute, kann die Variation des systemischen Risikos über den Zeitverlauf dargestellt werden. Ein steigendes Lambda bedeutet, dass eine Bank mehr relevante Verbindungen im Vergleich zur vergangenen Periode aufweist. Somit steht ein steigendes durchschnittliches Lambda für mehr relevante Verbindungen im Bankensystem und ein höheres systemisches Risiko (Yu et al. 2017; Mihoci et al. 2019).

Abbildung 3 stellt die Gesamtvernetzung und das durchschnittliche Lambda über den Zeitverlauf der Stichprobe dar. Die Vernetzung steigt in der Weltfinanzkrise stark an und erreicht Ende 2009 ihren Höhepunkt. Mit dem Ende der Krise sinkt auch die Gesamtvernetzung und das durchschnittliche Lambda. Diese sinkende Vernetzung in den Jahren nach der Weltfinanzkrise fällt jedoch im Vergleich zu den USA deutlich kleiner aus. Besonders der Rückgang des durchschnittlichen Lambdas gestaltet sich im europäischen Netzwerk geringer. Außerdem fällt in den USA die Gesamtvernetzung bereits zum Anfang und das systemische Risiko ab Mitte des Jahres 2009 (Härdle et al. 2016). Nach der Erholung bleiben im europäischen Bankensystem beide Maße bis auf einzelne kleinere Schwankungen auf konstantem Niveau. Während sich die Gesamtvernetzung auf ähnlich hohem Niveau wie vor der Krise bewegt, behält das durchschnittliche Lambda ein deutlich höheres Ausmaß bei.

Abbildung 3: Gesamtvernetzung & Durchschnitts-Lambda im europäischen Finanzsystem



Der spätere Erholungsbeginn sowie das konstant erhöhte systemische Risiko können vor allen Dingen mit dem Beginn der europäischen Staatsschuldenkrise und der daraus folgenden langanhaltend hohen Staatsverschuldung einzelner Staaten begründet werden. Diese Probleme halten zum Teil noch bis heute an und könnten in Verbindung mit neuen Unsicherheiten und Risiken ein konstant höheres systemisches Risiko mit sich gebracht haben. Es sind zusätzlich zwei Anstiege des durchschnittlichen Lambdas ab Mitte 2011 und um das Jahr 2015 zu erkennen. Der Anstieg Mitte 2011 kann auf die Probleme im öffentlichen Haushalt Spaniens sowie Italiens zurückgeführt werden. Diese wurden im Sommer 2011 öffentlich und übertrugen sich auch auf die heimischen Banken. Anfang 2012 folgten zwei Abstufungswellen der Ratings zahlreicher italienischer Institute durch die Agenturen Moody's und S&P (Moody's 2012; Reuters 2012). Dies verstärkte die Unsicherheit der Märkte, was das systemische Risiko stiegen lies. Darüber hinaus waren auch deutlich nach dem Höhepunkt der Finanzkrise weitere europäischen Banken, wie die spanischen Institute Bankia und CatalunyaCaixa sowie die deutsche WestLB, insolvent. Die hier entstandenen negativen Spillover auf andere Institute sowie die Sorge über weitere Insolvenzen tragen ebenfalls zum konstant höheren Vernetzungsgrad und systemischen Risiko bei. Der leichte Anstieg im Jahr 2015 fällt genau in den Zeitraum um die Debatte eines möglichen Brexits. Dies brachte weitere Unsicherheiten in den Markt, wodurch ein Sinken des durchschnittlichen Lambdas und der Gesamtvernetzung verhindert wurde.

Die Vernetzung auf Gruppenebene wird nach auf die Gruppe eingehenden und von der Gruppe ausgehenden Effekte aufgeteilt. Alle auf die Gruppe eingehenden Gesamteffekte werden dabei als

$$GE_{G,F}^{IN} = \sum_{i=1}^k \sum_{j \in G}^k |\hat{\beta}_{j|i}^F| \quad (22)$$

definiert, während von der Gruppe ausgehende Gesamteffekte als

$$GE_{G,F}^{OUT} = \sum_{i \in G}^k \sum_{j=1}^k |\hat{\beta}_{j|i}^F| \quad (23)$$

definiert werden. Dabei steht G für eine der zuvor definierten sechs Ländergruppen $G = \{ \text{FR/BE/NL, DE/AUT, UK, IT/GR, SP/POR, SKAND} \}$.

Abbildung 4 stellt die eingehenden Effekte auf die Ländergruppen $GE_{G,F}^{IN}$ dar. Die Graphen der Ländergruppen weisen eine einander ähnliche Struktur auf, die an den Graphen, der zuvor in Abbildung 3 dargestellten Gesamtvernetzung erinnert. Dies macht die vorherigen Erläuterungen auch hier gültig: Es lag ein erhöhtes eingehendes Risiko in der Weltfinanzkrise vor, das sich durch den Beginn der europäischen Staatsschuldenkrise weiter erhöhte und auch in den folgenden Jahren nicht auf Vorkrisenniveau sinken konnte, sondern für verschiedene

Ländergruppen auf individuellem Niveau schwankte. Dabei sind die beiden Gruppen DE/AUT und UK zu Beginn stärker betroffen als andere. Während über ausgehende Verbindungen auch ohne internes Wissen geurteilt werden kann, ist es schwierig eingehende Effekte ohne internes Wissen zu bewerten. Durch Kenntnis der Geschäftsschwerpunkte der Banken oder Länderrisiken, denen die Banken einzelner Ländergruppe ausgesetzt sind, können Schlüsse darüber gezogen werden, wie ihre Risikolage aussieht und entsprechend wie viel Risiko sie für andere ausstrahlen. Da hier eingehenden Effekte anderer europäischer Finanzinstitute betrachtet werden, bedarf es für eine Beurteilung dieser Effekte an genauer Kenntnis über die Geschäftsbeziehung der Institute der Ländergruppe, um zu begründen zu können, wieso gerade diese mehr Effekte aufnehmen als andere. Vor dem Hintergrund, dass Großbritannien und Deutschland die zwei wichtigsten Handelsplätze für Bankgeschäfte in Europa sind, macht eine erhöhte Verwundbarkeit der heimischen Banken in einer Krise auf den ersten Blick jedoch Sinn. Von welchen Instituten diese erhöhten eingehenden Spillover-Effekte kommen soll zu späterem Zeitpunkt auf Einzelinstitutsebene analysiert werden.

Abbildung 4: Eingehende Effekte nach Ländergruppe





Abbildung 5 stellt die ausgehenden Effekte $GE_{G,F}^{OUT}$ dar. Es ist keine Ländergruppe identifizierbar, die in der Weltfinanzkrise vermehrt Risiko ausstößt. Alle Linien liegen zu Beginn eng zusammen. Es kann also behauptet werden, dass alle Ländergruppen ähnlich stark durch die Krise betroffen waren und keine die negativen Spillover-Effekte aus Amerika besonders stark an Banken anderer Ländergruppen weitergegeben hat. Ab 2009, zu Beginn der Staatsschuldenkrise, steigen die ausgehenden Effekte aller Gruppen leicht an. Besonders auffällig ist dabei jedoch die Gruppe FR/BE/NL mit drei höheren Spitzen. Dies ist mit dem Bailout der belgischen Bank Dexia zu begründen, die zuerst in der Weltfinanzkrise und danach in der europäischen Staatsschuldenkrise hohe Verluste erleiden musste. Die Bank verbuchte 2008 Verluste in Höhe

von 3,3 Mrd. Euro und im zweiten Quartal 2011 einen Verlust in Höhe von 4 Mrd. Euro, vor allem aus Abschreibungen griechischer Staatsanleihen, was genau den Zeitpunkten der ersten beiden Anstiege entspricht. Als sich die griechische Krise Ende 2011 weiter verstärkte, entschied sich die belgische Regierung dazu Dexia zu verstaatlichen (Dexia 2009, 2011). Im Zeitraum nach der Weltfinanzkrise ist erkennbar wie sich die Linien mit der Zeit weiter voneinander entfernen. Einige Ländergruppen emittieren somit deutlich mehr Risiko als andere. Betrachtet man die europäische Staatsschuldenkrise und die folgenden Jahre, so kann ab Mitte des Jahres 2011 ein Anstieg der ausgehenden Effekte der Ländergruppe IT/GR beobachtet werden, der bis zum Stichprobenende auf hohem Niveau verbleibt. Ein ähnlicher Trend, allerdings in geringerem Ausmaß, ist auch für die Gruppe SP/POR beobachtbar. Dies zeigt, dass die Marktteilnehmer deutlich besorgter über den Zustand Italiens als den Zustand Spaniens waren. Auch negative Spillover-Effekte, die aus dem Brexit resultieren, sind bereits ab Mitte 2015 und somit vor dem Referendum Mitte 2016 zu beobachten. Der steigende Euroskeptizismus in der Bevölkerung, Wahlerfolge der UKIP (UK Independence Party) sowie Diskussionen und Gesetze über ein mögliches Referendum ließen von Großbritannien ausgehende Risiken scheinbar deutlich steigen. Die zuvor aufgestellten Vermutungen, dass Italien und Spanien sowie zu späterem Zeitpunkt Großbritannien für die zeitweisen Anstiege des systemischen Risikos verantwortlich sind, können hiermit also verifiziert werden.


Abbildung 5: Ausgehende Effekte nach Ländergruppe



Der große Unterschied zwischen den ausgehenden Spillover-Effekten der europäischen Peripherie im Vergleich zu den Ländern Kerneuropas ist dabei deutlich in Abbildung 6 zu erkennen. Hier werden die Gruppen FR/BE/NL, DE/AUT und SKAND zum Graphen Kerneuropa und die Gruppen SP/POR und IT/GR zum Graphen Peripherie aggregiert. Die Institute aus der Gruppe UK werden in dieser Betrachtung ausgeschlossen. Die von Instituten aus dem Kern Europas

ausgehenden Effekte weisen nach ihrem Höhepunkt im Jahr 2010 einen fallenden Trend auf, während die von Instituten aus der Peripherie ausgehenden Effekte einen steigenden Trend aufweisen. Zum Ende des Jahres 2012 überschreiten die ausgehenden Effekte der Peripherie die Effekte Kerneuropas und beide Graphen entfernen sich immer weiter voneinander. Die in Abbildung 5 erkennbaren Tendenzen sind hier somit noch einmal in aller Deutlichkeit zu erkennen.

Abbildung 6: Ausgehende Effekte europäische Peripherie vs. Kerneuropa



Im nächsten Schritt soll die Vernetzung auf Einzelinstitutsebene untersucht werden. Dazu werden die in den Netzwerkmatrizen N_F enthaltenen Koeffizienten analysiert, wodurch alle relevanten Beziehungen der Finanzinstitute dargestellt werden können. Der Effekt eines Finanzinstituts i auf ein Institut j im Fenster F ist demzufolge $E_{j,i}^F = |\hat{\beta}_{j|i}^F|$. Abbildungen 7, 8 und 9 zeigen beispielhaft alle relevanten Effekte zu drei markanten Zeitpunkten der Stichprobe als Netzwerkplots. Abbildung 7 zeigt das System zum 15. September 2008, was dem Tag der Lehmann Brothers Insolvenz entspricht, Abbildung 8 zum 10. Juni 2011 als die Sorgen um den Zustand von Spanien und Italien anstiegen und Abbildung 9 zum 20. Mai 2016 kurz vor dem Referendum über den Brexit, zu einem Zeitpunkt, zu dem die Unsicherheit über den Ausgang noch hoch war. Aus diesen Netzwerkplots lassen sich Muster und Gesamtzusammenhänge einfach erkennen. Aufgrund der hohen Vernetzung des gesamten Finanzsektors, der somit hohen Anzahl an dargestellten eingehenden und ausgehenden Effekten sowie fehlender Informationen über die genaue Höhe der Effekte, eignen sie sich jedoch nicht für eine Analyse von Details.⁴

⁴ Bei einem hohen Vernetzungsgrad des Systems können durch die Darstellungsweise Informationen verloren gehen. So werden Pfeile aus ähnlichen Richtungen übereinander dargestellt und Verbindungen, die zuerst geplottet werden, könnten überzeichnet werden und somit in den Hintergrund geraten, wodurch Differenzen zwischen den Grafiken und Detailmessungen entstehen könnten.

Abbildung 7: Netzwerkplot zum 15. September 2008




Abbildung 8: Netzwerkplot zum 10. Juni 2011





Abbildung 9: Netzwerkplot zum 20. Mai 2016



Zudem stellen die Netzwerkplots Auszüge zu einem festen Zeitpunkt der Stichprobe dar, die ggf. von den üblichen Zusammenhängen abweichen können. Deshalb sollen die aus den Abbildungen 7-9 erkenntlichen Zusammenhänge im Folgenden aufgelistet werden und in einem darauffolgenden Schritt mittels weiterer informativer Kennzahlen überprüft und ergänzt werden.

Auch über einen optischen Vergleich der drei Netzwerkplots ist der Abbau des Vernetzungsgrades über den Zeitverlauf erkennbar. In Abbildung 7 bestehen deutlich mehr Verbindungen als in den Abbildungen 8 und 9. Das Netzwerk europäischer Banken besteht hauptsächlich aus einer Vielzahl an kleinen Spillover-Effekten, jedoch sind auch einige starke gegenseitige Beziehungen zu beobachten, die vor allem innerhalb von Ländergruppen auftreten. So bestehen z. B. starke gegenseitige Beziehungen zwischen der Banco Santander und der BBVA (in allen drei Abbildungen), der Swedbank und der Skandinaviska Enskilda (in Abbildung 7) sowie der Unicredit Group und der Intesa Sanpaolo. Manche dieser Beziehungen sind dabei beständig, andere wiederum treten nur vereinzelt auf. Generell gibt es kein Einzelinstitut, das eine hohe Anzahl an starken Spillover-Effekten an andere Institute weitergibt. Zu den betrachteten Zeitpunkten sind zwei bis drei starke, von einem einzelnen Institut ausgehende Spillover-Effekte

(je nach betrachtetem Plot) das Maximum. Diese starken Spillover-Effekte können jedoch relativ schnell durch eine hohe Anzahl kleinerer Verbindungen an Bedeutung verlieren, was zeigt, dass kein einzelnes Institut als Auslöser für die Schwierigkeiten des Bankensystems zu den verschiedenen Zeitpunkten identifiziert werden kann.

Es sind jedoch einzelne Institute auszumachen, die vermehrt Risiko-Spillover aufnehmen wie z. B. die Royal Bank of Scotland in Abbildung 7 oder die beiden irischen Banken Allied Irish Banks und Bank of Ireland in Abbildung 8. In Abbildung 8 und 9 fallen besonders die Banken der Gruppe FR/BE/NL mit starken Spillover-Effekten auf. Dies scheint ein erster Hinweis darauf zu sein, dass die erhöhten ausgehenden Risiken dieser Gruppe im Ländergruppenvergleich nicht ausschließlich auf die Insolvenz der belgischen Dexia zurückzuführen sind. Zuletzt fällt besonders in den Abbildungen 7 und 8 das stark untereinander vernetzte italienische Bankensystem auf.

Um einen objektiven Eindruck über den Vernetzungsgrad des Systems sowie die Menge an eingehenden bzw. ausgehenden Effekte eines jeden Einzelinstitutes zu erhalten, werden in den Netzwerkmatrizen alle ausgehenden bzw. eingehenden Verbindungen, also die Anzahl aller Elemente einer jeden Spalte bzw. Zeile, die ungleich null sind, gezählt. Die Ergebnisse dieser Rechnung sind sowohl für einzelne Institute als auch für die Ländergruppen zu allen drei Zeitpunkten der Netzwerksplots in Tabelle 4 aufgelistet. Auf Einzelinstitutsebene ist zu erkennen, dass sich Effekte eher auf einzelne Institute bündeln, als dass sie vermehrt von einem einzelnen Institut emittiert werden. So erhält die Bank of Ireland zum Zeitpunkt $t=2$, also dem 10. Juni 2011, 25 eingehende Spillover-Effekte, während die Deutsche Bank zusammen mit der Bank of Ireland zu diesem Zeitpunkt mit 13 ausgehenden Verbindungen die meisten Spillover-Effekte emittiert. Ähnlich ist es zum Zeitpunkt $t=3$, dem 20. Mai 2016. Hier erhält die National Bank of Greece 25 eingehende Effekte, während Dexia und die DNB mit jeweils 12 Spillovern, die meisten Effekte emittieren. Zum Zeitpunkt $t=1$, dem 15. September 2008, nimmt die Royal Bank of Scotland 20 eingehende Spillover auf, während 16 Effekte von der Banco BPM emittiert werden. Aggregiert man diese Ergebnisse auf die Ländergruppen, so wird erkenntlich, dass die UK-Gruppe durch eine hohe Vernetzung bezüglich der Anzahl an eingehenden Effekten charakterisiert werden kann. Die hohen eingehenden Risiken aus der Ländergruppenanalyse sind somit auf die hohe Anzahl an Effekten, die auf die Bank of Ireland, Royal Bank of Scotland und Allied Irish Banks eingehen, zurückzuführen. Die eingehenden Risiken der Gruppe DE/AUT, die gefunden wurden, können jedoch nicht von der Anzahl an eingehenden Effekten stammen, da die Einzelinstitute in Tabelle 2 nicht mit sonderlich hohen Zahlen auffallen. Die

erhöhten eingehenden Effekte dieser Gruppe müssen somit aus stärkeren eingehenden Verbindungen, also der Höhe einzelner Effekte, resultieren.

Tabelle 4: Anzahl eingehender und ausgehender Effekte nach Institut und Ländergruppe

Anzahl Effekte							Anzahl Effekte						
Ausgehend			Eingehend			Institut	Ausgehend			Eingehend			Institut
Institut	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	
HSBC	15	11	10	7	9	6	SVK	15	9	6	4	2	6
BNP	12	8	10	5	7	5	SEA	11	9	7	9	6	5
DBK	13	13	8	10	8	9	KBC	9	8	8	12	11	9
BARC	10	10	8	13	9	5	DEX	12	11	12	15	12	16
CRDA	11	9	9	14	8	6	SWED	9	7	7	9	11	2
SGE	8	7	10	15	12	7	ERS	10	10	9	9	6	11
RBS	12	9	9	20	9	8	BMPS	8	10	5	7	6	16
SAN	11	9	7	7	11	6	BSAB	8	9	10	6	11	11
ING	14	11	11	13	4	6	POP	9	8	8	12	11	14
LLOY	8	9	7	13	12	7	BIRG	13	13	8	17	25	9
UCG	8	11	10	10	6	9	BP	16	9	8	12	16	15
NDAS	8	10	11	6	4	2	A5G	10	9	7	16	23	22
ISP	10	10	10	9	7	9	ETE	10	6	8	19	16	25
BBVA	8	8	9	3	6	3	POH	12	10	-	7	5	-
CBKX	9	12	10	11	12	6	UNI	13	12	9	12	9	0
STAN	9	8	8	14	13	17	BCP	12	11	9	18	8	14
DAB	11	11	11	6	15	9	BKES	14	8	-	10	5	-
DNB	9	10	12	13	8	6	MB	12	10	10	6	2	0

Ø-Anzahl Effekte pro Bank							Ø-Anzahl Effekte pro Bank						
Ausgehend			Eingehend			Länder- gruppe	Ausgehend			Eingehend			Länder- gruppe
Länder- gruppe	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	t ₁	t ₂	t ₃	
FR/BE/NL	11	9	10	12	9	8	IT/GR	11	10	10	11	9	11
DE/AUT	11	12	9	10	7	9	SP/POR	10	9	7	9	9	8
UK	11	10	8	14	14	11	SKAND	11	9	8	8	7	5

Die Höhe der Effekte soll deshalb als Nächstes untersucht werden. Dazu wird zuerst ein Schwellenwert für die Darstellung der Verbindungen in den Netzwerkplots definiert. In den Abbildungen 9 bis 11 werden nur noch Effekte dargestellt, die größer als der Durchschnittseffekt sind, um die Haupteffekte besser identifizieren zu können. Alle anderen Effekte werden in diesem Schritt auf null herabgesetzt. Dabei wird sichtbar, dass tatsächlich zum Zeitpunkt der Lehman Brothers Insolvenz zwei starke eingehende Effekte aus der skandinavischen Gruppe auf die DE/AUT Gruppe eingehen. Zum einen von der Skandinaviska Enskilda auf die Erste Group Bank und zum anderen von der Danske Bank auf die Commerzbank. Generell fällt die skandinavische Bankengruppe zu diesem Zeitpunkt mit einer erhöhten Anzahl starker Spillover-Effekte auf Institute anderer Gruppen auf. Zum zweiten gewählten Zeitpunkt, also Abbildung 10, gehen vermehrt starke Effekte von den britischen Finanzinstituten auf andere

Abbildung 10: Reduzierter Netzwerkplot zum 15. September 2008




Abbildung 11: Reduzierter Netzwerkplot zum 10. Juni 2011





Abbildung 12: Reduzierter Netzwerkplot zum 20. Mai 2016



Ländergruppen aus, während in Abbildung 11 und somit dem letzten fixen Zeitpunkt deutlich weniger starke Verbindungen zu erkennen sind. Zudem sind in Abbildung 11 keine Regelmäßigkeiten zu erkennen. Auffällig ist jedoch, dass innerhalb des italienischen und skandinavischen Bankensektors keine starken Spillover-Effekte mehr vorhanden sind. Wie bereits in den vollständigen Netzwerkplots gesehen, ist der italienische Bankensektor stark untereinander vernetzt. Es scheinen zu diesem Zeitpunkt zwar keine starken Spillover-Effekte zu geben, Tabelle 4 zeigt jedoch, dass die italienischen Banken eher überdurchschnittlich viele Verbindungen aufweisen. Somit ist die hohe Anzahl an schwachen Effekten hier nicht sichtbar. Im skandinavischen Bankensektor haben sich die Spillover-Effekte über die Zeit deutlich verringert, was auch an den Netzwerkplots in Abbildungen 7 bis 9 sowie der sinkenden durchschnittlichen Anzahl an Verbindungen pro Bank in Tabelle 4 erkenntlich ist. Dies hängt wahrscheinlich mit der starken Kapitalausstattung der skandinavischen Banken zusammen, die bereits nach der nationalen Bankenkrise in den 90er-Jahren verstärkten Regulierungsmaßnahmen unterliegen und somit deutlich besser gegen Schocks geschützt sind (S&P Global Market Intelligence 2020).

Die starken gegenseitigen Spillover-Effekte, die bereits im Gesamtnetzwerk identifiziert wurden, sind nun in allen drei Abbildung deutlich erkennbar. Diese gegenseitigen Beziehungen treten dabei ausschließlich bei Instituten derselben Nationalität auf, was zeigt, dass Spillover-Effekte vermehrt auf nationaler Ebene auftreten. Wie bereits erwähnt, sind Netzwerkplots statische Aufnahmen zu einem festen Zeitpunkt, die ggf. andere als die üblichen Verbindungen darstellen könnten. Zudem können starke Effekte durch eine Vielzahl von schwächeren Effekten, die auf den reduzierten Plots nicht erkennbar sind, relativiert werden. Andersherum kann jedoch auch eine hohe Anzahl an Effekten durch starke Effekte relativiert werden. Deshalb sollen die einzelnen Institute zum Schluss durch die Summen aller eingehenden bzw. ausgehenden Effekte über alle Zeitfenster miteinander verglichen werden. Diese können wie folgt berechnet werden:

$$Ges^{IN} = \sum_{i=1}^k |\hat{\beta}_{ji}^F|, \quad (24)$$

$$Ges^{OUT} = \sum_{j=1}^k |\hat{\beta}_{ji}^F|. \quad (25)$$

Die im vorherigen Absatz identifizierte zentrale Rolle der nationalen Ebene kann auch durch die Tabellen 5 und 6 bestätigt werden. Tabelle 5 zeigt die drei stärksten eingehenden und ausgehenden Verbindungen für die 15 größten Institute nach Höhe der Marktkapitalisierung zum 5% und 95% Quantil. Die hier ermittelten Effekte werden ebenfalls über die Summe der Fenster, jedoch nur für ein spezielles Paar $j|i$ ermittelt.

In allen Fällen außer im Falle der ING besteht die stärkste Verbindung zwischen zwei Instituten aus demselben Herkunftsland.⁵ Für einen Großteil der hier aufgelisteten Finanzinstitute sind sogar die ersten beiden stärksten Verbindung herkunftslandintern. So ist z. B. die BBVA, die eingehende Effekte der Banco Santander erhält, zusätzlich mit der Banco Popular Español durch die zweitstärksten eingehenden sowie ausgehenden Effekte verbunden. Die Banco Santander wiederum ist ebenfalls mit beiden Instituten stark gegenseitig verbunden. Es bilden sich somit starke nationale Netze, die dann von internationalen Verbindungen umgeben werden. Diese Beobachtung ist besonders vor dem Hintergrund, dass Institute des gleichen Herkunftslandes vermehrt gemeinsame Schuldner aufweisen, einleuchtend. Vergleicht man die verbundenen Institute zum 5 %- und 95 %-Quantil, so unterscheiden sich diese signifikant voneinander. Zwar bleibt der stärkste ein- bzw. ausgehende Effekt fast immer unverändert, jedoch variiert die zweit- und/oder die drittstärkste Verbindung in vielen Fällen. So erhält die HSBC als

⁵ Die ING ist das einzige niederländische Institut in der Stichprobe, somit können keine nationalen Effekte gemessen werden.

größtes Institut nach Marktkapitalisierung zum 5 %-Quantil eingehende Effekte von Standard Chartered, der Royal Bank of Scotland und Dexia, während sie bei Betrachtung des 95 %-Quantils Effekte von Standard Chartered, Barclays und der BNP Paribas erhält. Dies ist ein Beweis dafür, dass die Schätzung des Tail-Risks mittels Quantilregression der Messung durchschnittlicher Effekte bevorzugt werden sollte, um Zusammenhänge auf verschiedenen Preisebenen (hier dem linken Ende der Renditeverteilung) angemessen darzustellen.

Tabelle 5: Auflistung der drei stärksten eingehenden und ausgehenden Effekte pro Institut

Rang	Ticker	$\tau = 0,05$		$\tau = 0,95$	
		Eingehende Effekt von	Ausgehende Effekte zu	Eingehende Effekte von	Ausgehende Effekte zu
1	HSBC	STAN, RBS, DEXB	STAN, BNP, RBS	STAN, BARC, BNP	STAN, BNP, A5G
2	SAN	BBVA, POP, UCG	BBVA, BSAB, POP	BBVA, BSAB, CBK	BBVA, POP, BSAB
3	BNP	CRDA, SGE, ING	SGE, DBK, NDAS	SGE, CRDA, DBK	SGE, CRDA, ING
4	LLOY	RBS, BARC, BIRG	BARC, RBS, A5G	RBS, BARC, A5G	RBS, BARC, ETE
5	A5G	BIRG, LLOY, SWED	BIRG, RBS, LLOY	BIRG, CRDA, ERS	BIRG, LLOY, CBK
6	BARC	RBS, LLOY, STAN	RBS, LLOY, DBK	RBS, LLOY, BP	RBS, LLOY, HSBC
7	BBVA	SAN, POP, SGE	SAN, POP, BSAB	SAN, POP, ISP	SAN, POP, A5G
8	RBS	BARC, LLOY, DEXB	BARC, LLOY, DAB	BARC, LLOY, KBC	BARC, LLOY, CBK
9	STAN	HSBC, DAB, DBK	HSBC, BARC, BIRG	HSBC, ING, BARC	HSBC, DAB, ETE
10	NDAS	SEA, SWED, SVK	SVK, SEA, SWED	SEA, SWED, DNB	SEA, SWED, DNB
11	ING	SGE, MB, SVK	SVK, BNP, KB	SGE, BNP, ISP	STAN, BNP, BIRG
12	DBK	CBK, BNP, BARC	CBK, BNP, STAN	CBK, SGE, BNP	CBK, BNP, SGE
13	SGE	CRDA, BNP, ISP	CRDA, BNP, ING	CRDA, BNP, ING	CRDA, BNP, ING
14	UCG	ISP, BP, UNI	ISP, BP, MB	ISP, BP, SGE	ISP, BP, UNI
15	ISP	UCG, BP, SGE	UCG, BP, SGE	UCG, BP, SGE	UCG, MB, BP

Tabelle 6 quantifiziert die Höhe der zehn stärksten Verbindungen zwischen zwei Einzelinstituten über den Zeitverlauf der Stichprobe. Sie stellt somit ein Ranking der stärksten Verbindungen aus Tabelle 5 dar. Dabei ist zu erkennen, dass die gegenseitigen nationalen Verbindungen auch die stärksten existierenden Verbindungen darstellen. Die gegenseitigen Spillover-Effekte zwischen den spanischen Banken BBVA und Banco Santander stellen die über den Zeitverlauf stärksten Verbindungen dar. Dazu kommen gegenseitige Spillover zwischen den schwedischen Banken Swedbank und Skandinaviska Enskilda, den spanischen Banken Banco Popular Español und Banco de Sabadell sowie eine Verbindung von der italienischen Intesa Sanpaolo zur Unicredit Group. Es ist zudem auffällig, dass die Royal Bank of Scotland mit Barclays und der Lloyds Banking Group mit gleich zwei gegenseitigen Verbindungen in diesem Ranking vertreten ist.

Vergleicht man die Verbindungen der reduzierten Netzwerkplots mit den drei relevantesten Beziehungen aus Tabelle 5, fällt auf, dass die hier abgebildeten starken ausgehenden Spillover-Effekte auf andere Ländergruppen so gut wie nie Teil der relevantesten Verbindungen der entsprechenden Institute sind. Beispiele dafür sind die ausgehenden Effekte der ING sowie die von der Erste Group Bank eingehenden Effekte der HSBC und Royal Bank of Scotland in Abbildung 11. Dies ist ein Hinweis darauf, dass starke ländergruppenübergreifende Effekte vor allem bei besonderen Ereignissen bzw. in besonderen Phasen auftreten.

Tabelle 6: Auflistung der 10 stärksten Effekte auf Einzelinstitutsebene

Rang	Von...	Zu...	Höhe
1	BBVA	SAN (Banco Santander)	325,45
2	SAN (Banco Santander)	BBVA	321,32
3	SWED (Swedbank)	SEA (Skandinaviska Enskilda)	278,20
4	SEA (Skandinaviska Enskilda)	SEWD (Swedbank)	258,10
5	POP (Banco Popular Español)	BSAB (Banco de Sabadell)	233,18
6	BARC (Barclays)	RBS (Royal Bank of Scotland)	219,39
7	BSAB (Banco de Sabadell)	POP (Banco Popular Español)	200,67
8	RBS (Royal Bank of Scotland)	BARC (Barclays)	194,53
9	RBS (Royal Bank of Scotland)	LLOY (Lloyds Banking Group)	191,06
10	ISP (Intesa Sanpaolo)	UCG (Unicredit Group)	188,41

Betrachtet man nun die Summe aller eingehenden bzw. ausgehenden Effekte eines Institutes wie in Gleichungen 24 und 25 beschrieben, so können die Institute mit den meisten empfangenen bzw. emittierten Spillover-Effekten identifiziert werden. Die Top 10 Spillover-Empfänger werden in Tabelle 7 und die Top 10 Spillover-Sender in Tabelle 8 dargestellt. Beide Tabellen enthalten zudem den Rang des Institutes, wenn diese nach Marktkapitalisierung bzw. Höhe der Aktiva sortiert werden.

Es ist auffällig, dass gerade die kleineren Finanzinstitute der Stichprobe hier stärker vertreten sind. In den Top 10 der Spillover-Empfänger tauchen mit der HSBC, der BNP Paribas und Barclays drei der zehn größten Institute nach Marktkapitalisierung auf, während bei Sortierung nach Höhe der Aktiva fünf der zehn größten Institute vertreten sind. In den Top 10 der Spillover-Empfänger befinden sich mit Barclays und der Royal Bank of Scotland sogar nur zwei der größten Institute nach Marktkapitalisierung hierzu kommt bei Sortierung nach Höhe der Aktiva noch die Société Générale. Stattdessen führt die Bank of Ireland als 27. Institut nach Marktkapitalisierung die Risiko-Empfänger an, knapp gefolgt von der Deutschen Bank und der Commerzbank, die ebenfalls nicht der Top 10 nach Marktkapitalisierung angehören. Die Risiko-

Sender werden von der französischen Société Générale und der italienischen Banco BPM als 13. und 34. Institut nach Marktkapitalisierung angeführt. Die Summen der Spillover-Effekte beider Top 10 Rankings liegen sehr dicht aneinander, es gibt keine großen Sprünge zwischen einzelnen Platzierungen. Das System europäischer Banken besteht somit zwar aus mehr und weniger stark verbundenen Instituten, die überdurchschnittlich hoch vernetzten Institute sind jedoch alle ähnlich stark vernetzt. Zudem sind die Institute, zwischen denen die stärksten Effekte auftreten nicht führend, wenn die Gesamtsumme der eingehenden und ausgehenden Effekte betrachtet wird. Das System wird demzufolge eher durch die Vielzahl an mittleren und schwächeren Verbindungen als durch sehr starke Effekte charakterisiert. Somit zeigt sich, wieso es wichtig ist nicht nur die größten Institute der Aufsicht zu unterstellen, sondern auch mittelgroße Institute, die mit einer hohen Anzahl anderer Institute vernetzt sind, genauer zu beobachten: Die von Zeit zu Zeit aus anderen Ländergruppen auf ein Institut eingehenden starken Effekte könnten sich gerade in Europa über den hohen nationalen Vernetzungsgrad schnell zu einem größeren Risiko für den gesamten nationalen Bankensektor entwickeln. Kleinere bzw. mittelgroße Institute mit vielen Verbindungen sind zwar nicht als einzelnes Institut systemrelevant, eine Beobachtung durch die Regulierungsbehörde ist jedoch trotzdem notwendig. Dies ist der Fall, da eine Insolvenz über Ansteckungsmechanismen zu einer Welle an weiteren Insolvenzen kleinerer Institute führen kann, die in der Folge dann auch große systemrelevante Banken in Gefahr bringen könnte.

Die Société Générale und die Banco BPM sind dabei exzellente Beispiele für die Charakterisierung des europäischen Bankensektors: Beide Banken weisen keine extrem starken Verbindungen mit anderen Instituten auf (Vgl. Tabelle 6). Die Société Générale ist je nach Kennzahl eine große bzw. mittelgroße Bank. Sie weist eine durchschnittliche Anzahl, in den drei reduzierten Netzwerkplots, jedoch überdurchschnittlich starke ausgehende Effekte auf andere Institute auf. Die Banco BPM ist dagegen eines der kleinsten Institute der Stichprobe, ist jedoch mit einer hohen Anzahl anderer Institute verknüpft. Sie emittiert somit über die Vielzahl an Verbindungen, anstatt über die überdurchschnittliche Stärke der Effekte, das ausgehende Risiko.

Tabelle 7: Top 10 Institute nach der Summe eingehender Effekte

Rang	Risikoempfänger	Summe eingehender Effekte	Rang nach MK	Rang nach Aktiva
1	BIRG (Bank of Ireland)	1110,78	27	28
2	DBK (Deutsche Bank)	1109,46	12	3
3	CBK (Commerzbank)	1107,69	23	15
4	MB (Mediobanca)	1091,70	32	36
5	HSBC	1089,58	1	1
6	BNP (BNP Paribas)	1086,77	3	2
7	CRDA (Crédit Agricole)	1082,01	16	5
8	NDAS (Nordea Bank)	1080,03	10	12
9	BARC (Barclays)	1079,55	6	4
10	DAB (Danske Bank)	1074,48	22	17

Tabelle 8: Top 10 Institute nach der Summe ausgehender Effekte

Rang	Risikosender	Summe ausgehender Effekte	Rang nach MK	Rang nach Aktiva
1	SGE (Société Générale)	1298,03	13	6
2	BP (Banco BPM)	1285,58	34	29
3	BARC (Barclays)	1220,91	6	4
4	RBS (Royal Bank of Scotland)	1214,59	8	7
5	SEA (Skandinaviska Enskilda)	1211,64	20	20
6	UCG (Unicredit Group)	1200,09	14	11
7	BIRG (Bank of Ireland)	1170,01	27	28
8	SWED (Swedbank)	1161,32	18	23
9	ISP (Intesa Sanpaolo)	1158,37	15	13
10	POP (Banco Popular Español)	1103,77	26	27

Die Ergebnisse der Netzwerkanalyse können dementsprechend wie folgt zusammengefasst werden:

1. Der Vernetzungsgrad und besonders das systemische Risiko bleiben im europäischen Bankensystem aufgrund weiter bestehender Risiken auch nach der Weltfinanzkrise vergleichsweise hoch.
2. Kein Einzelinstitut ist für einen sehr hohen Anteil an Spillover-Effekten verantwortlich. Bei Betrachtung von Institutsgruppen sind nach der Weltfinanzkrise erhöhte ausgehende Spillover-Effekte aus der europäischen Peripherie erkennbar.
3. Nationale Verbindungen zwischen Finanzinstituten weisen wegen ihrer Anzahl und Stärke einen besonders hohen Stellenwert auf. Überdurchschnittlich große Spillover-Effekte, aus anderen Ländern gehen jedoch vereinzelt von anderen als den Hauptgeschäftspartnern ein.

4. Das Bankensystem wird über eine Vielzahl kleiner und mittlerer Spillover-Effekte definiert. „Kleinere“ Institute können dabei über eine hohe Anzahl an Spillover-Effekten systemrelevant werden.

Im Folgenden soll der Index der systemischen Risiko Empfänger SRE_j und der systemischen Risiko Sender SRS_j wie in Gleichungen 19 und 20 beschrieben berechnet werden. Ist ein Institut ausschließlich mit kleinen Instituten verknüpft, so macht es dies weniger systemrelevant, da die negativen Spillover-Effekte bezogen auf die Gesamtgröße des Marktes noch beherrschbar wären. Ist es jedoch vermehrt mit großen Instituten verbunden, so steigt die Systemrelevanz, da Spillover-Effekte nun auch die große Bank und somit immer mehr Marktmasse in eine Negativspirale ziehen können. Deshalb beziehen beide Indizes zusätzlich zur Höhe der Spillover-Effekte die Größe des Institutes i sowie die Größe der mit diesem Institut verknüpften Institute ein, wodurch die Begriffe „too big to fail“ und „too connected to fail“ in einem Maß zusammengeführt werden.

In beiden Indizes ist Größe weiterhin die treibende Variable: Neun der zehn größten Institute nach Marktkapitalisierung sind auch Teil der Top 10 beider Indizes. Die Vernetzung der Institute untereinander spielt jedoch definitiv eine Rolle für die Reihenfolge des Rankings. Der Index systemischer Risiko Sender verändert sich dabei verglichen zur Reihenfolge nach Marktkapitalisierung stärker als der Index systemischer Risiko Empfänger. Während beim SRE die vier größten Institute auch die vier größten Risikoempfänger darstellen, stehen beim SRS Barclays und die Royal Bank of Scotland als sechst- bzw. achtgrößtes Institut auf den ersten beiden Rängen. Erst danach folgen die Banco Santander und die HSBC als zweitgrößtes und größtes Institut nach Marktkapitalisierung. Es kann somit festgestellt werden, dass in Europa weiterhin vor allem die großen Banken systemrelevant sind. Diese Feststellung resultiert aus den Ergebnissen der Netzwerkanalyse, die gezeigt hat, dass von keinem Institut sehr starke Effekte ausgehen und generell der Unterschied in der Höhe emittierter Effekte zwischen Instituten nicht sehr hoch ist. Werden die Effekte in der Berechnung der Indizes mit der Marktkapitalisierung gewichtet, reicht die Stärke der Effekte mittelgroßer Institute nicht aus, um in die Top 10 systemrelevanter Institute zu gelangen.

Tabelle 9: Top 10 Institute nach dem Index der systemischen Risiko Empfänger

Rang	Risikoempfänger	SRE	Rang nach MK	Rang nach Aktiva
1	HSBC	1.78e+20	1	1
2	BNP (BNP Paribas)	9.90e+19	3	2
3	SAN (Banco Santander)	8.49e+19	2	8
4	LLOY (Lloyds Banking Group)	8.21e+19	4	10
5	BBVA	8.11e+19	7	14
6	BARC (Barclays)	7.30e+19	6	4
7	RBS (Royal Bank of Scotland)	6.70e+19	8	7
8	A5G (Allied Irish Banks)	6.59e+19	5	30
9	STAN (Standard Chartered)	5.17e+19	9	16
10	ING	4.52e+19	11	9

Tabelle 10: Top 10 Institute nach dem Index der systemischen Risiko Sender

Rang	Risikosender	SRS	Rang nach MK	Rang nach Aktiva
1	BARC (Barclays)	9.90e+19	6	4
2	RBS (Royal Bank of Scotland)	9.49e+19	8	7
3	SAN (Banco Santander)	9.23e+19	2	8
4	HSBC	8.64e+19	1	1
5	BBVA	8.62e+19	7	14
6	BNP (BNP Paribas)	8.59e+19	3	2
7	LLOY (Lloyds Group)	8.03e+19	4	10
8	A5G (Allied Irish Banks)	6.84e+19	5	30
9	SGE (Société Générale)	5.28e+19	13	6
10	STAN (Standard Chartered)	5.12e+19	9	16

Auffällig am Index der systemischen Risiko Empfänger ist jedoch das Fehlen der Deutschen Bank, obwohl sie auf Platz zwei der Summe eingehender Effekte liegt. Dies kann verschiedene Gründe haben, so hat die Deutsche Bank im Vergleich zur Höhe ihrer Aktiva eine geringe Marktkapitalisierung. Da zur Gewichtung der Spillover-Effekte die Marktkapitalisierung anstatt der Höhe der Aktiva gewählt wurde, könnte die Deutsche Bank aus den Top 10 verdrängt worden sein. Ein Gegenargument hierzu ist jedoch die französische Société Générale, die die höchste Summe an ausgehenden Effekten aufweist. Ihre Marktkapitalisierung ist sogar leicht geringer als die der Deutschen Bank und trotzdem wird sie als Teil der Top 10 SRS gelistet. Es ist somit zu vermuten, dass die Deutsche Bank vergleichsweise viele und bzw. oder stärkere Spillover-Effekte von kleineren Instituten erhält und deshalb über die Gewichtung aus den Top 10 herausfällt. Des Weiteren ist die Präsenz der Allied Irish Banks in beiden systemischen Risiko-Indizes auf den ersten Blick verwunderlich. Sie kann jedoch damit erklärt werden, dass das Institut eine hohe Marktkapitalisierung im Vergleich zur Höhe der Aktiva besitzt und somit

durch die Gewichtung der Spillover-Effekte höher gelistet wird. Letztendlich hängt die Betrachtung ihrer Systemrelevanz also von der Definition der Größe einer Bank ab.

Zum Schluss sollen die Ergebnisse noch mit anderen Messungen für systemisches Risiko im europäischen Bankensystem verglichen werden. Dazu sollen die vom Finanzstabilitätsrat veröffentlichten Listen der global systemrelevanten Banken (G-SIBs), die Messungen der Varianzzerlegung in vektorautoregressiven Modellen nach Demirer et al. (2018) sowie dem systemischen Risiko Beta nach Betz et al. (2016) als Referenz verwendet werden.

Tabelle 11 zeigt alle G-SIBs im Zeitraum von 2011-2017 sowie die systemrelevantesten Banken der beiden anderen Ansätze. Je nach Ansatz werden Institute zusätzlich gruppiert, wobei Gruppe 4 die Institute mit der höchsten Systemrelevanz enthält. Im Falle der G-SIBs dienen die Körbe, die auch die Höhe des Kapitalpuffers bestimmen, als Gruppierungsmerkmal. Wird eine Bank im Zeitverlauf in verschiedenen Körben gelistet, wird derjenige gewählt, dem sie am längsten zugewiesen war. Die Darstellung von Netzwerken in vektorautoregressiven Modellen basiert zum Großteil auf grafischen Darstellungen. Die Gruppierung erfolgt nach der Stärke der ausgehenden Spillover-Effekte eines Institutes, die in Demirer et al. (2018) mittels Farbskala von grün bis rot vorgenommen wird. Dabei entspricht grün schwachen und rot starken Spillover-Effekten. Die Farbabstufungen werden in Tabelle 11 in vier Gruppen unterteilt. Als Referenzgrafik wird dazu das in Demirers Arbeit als Darstellung 2 bezeichnete Banknetzwerk von 2003-2014 gewählt. Betz et al. (2016) bieten grafische als auch numerische Darstellungen von Systemrelevanz in ihrer Arbeit an. Hier wird der numerische Wert des realisierten systemischen Risiko Betas im Oktober 2008 als Referenz gewählt. Es werden für alle drei Vergleichsmaße nur die Institute, die auch im Datensatz dieser Arbeit betrachtet werden in Tabelle 11 gelistet.

Die G-SIBs werden nach Befragung der nationalen Behörden, durch den Finanzstabilitätsrat veröffentlicht. Neun der Top 10 SRS und SRR Institute werden von 2011-2017 auch hier als systemrelevant eingestuft. Dabei verändern sich die gelisteten Institute jedoch über den Zeitverlauf. Betrachtet man die einzelnen Listen, so wird Lloyds im Jahr 2012 und die BBVA nach ihrem ersten Erscheinen im Jahr 2012 im Jahr 2015 als weniger systemrelevant eingeschätzt und von der Liste entfernt. Dafür wird Standard Chartered jedoch ab dem Jahr 2012 vom Finanzstabilitätsrat als systemrelevant gelistet⁶.

⁶Ein Überblick über die Listen aller Jahre ist unter: <https://www.fsb.org/work-of-the-fsb/policy-development/addressing-sifis/global-systemically-important-financial-institutions-g-sifis/> generierbar.

Tabelle 11: Ergebnisse anderer systemischer Risikomaße

FSB G-SIBs		Demirer et al.		Betz et al.
Gruppe 4	HSBC	Gruppe 4	BNP Paribas Deutsche Bank	1. Dexia 2. Bank of Ireland
Gruppe 3	Deutsche Bank BNP Paribas Barclays	Gruppe 3	Santander Société Générale ING BBVA	3. Royal Bank of Scotland 4. Commerzbank 5. KBC 6. Crédit Agricole
Gruppe 2	RBS	Gruppe 2	Crédit Agricole Unicredit Barclays Intesa Sanpaolo	7. Barclays 8. Société Générale 9. Lloyds 10. ING
Gruppe 1	Crédit Agricole BBVA Santander ING Société Générale Standard Chartered Unicredit Lloyds Dexia	Gruppe 1	Lloyds RBS Standard Chartered HSBC	11. Unicredit 12. Allied Irish Banks 13. Standard Chartered 14. Intesa Sanpaolo 15. BNP Paribas 16. Banco Santander 17. Pohjola 18. BBVA 19. Deutsche Bank 20. Svenska Handelsbanken

Die in Demirer et al. (2018) identifizierten Institute sind denen der G-SIBs als auch den hier identifizierten SRS und SRR sehr ähnlich. Die gesamten Top 10 der Risikosender und Risikoempfänger werden auch von ihrem vektorautoregressiven Modell als die am systemrelevantesten Institute eingeschätzt. Bemerkenswert ist allerdings, dass die HSBC eine vergleichsweise geringe Relevanz aufweist. Dies ist jedoch mit der Verwendung der ausgehenden Effekte als Kategorisierungsmerkmal in Tabelle 11 zu erklären. Die Größe des Institutes spielt in der Kategorisierung keine Rolle, da bei Betrachtung zweier Merkmale eine eindeutige Zuordnung nicht möglich wäre. Zudem identifiziert die Arbeit dieser Autoren eingehende Effekte nicht im Detail. Da die HSBC nicht Teil der Top 10 Institute nach der Summe der ausgehenden Effekte in Tabelle 8 ist, sondern lediglich eine sehr hohe Anzahl an Spillover-Effekten von anderen Instituten erhält, sind die hier erhaltenen Ergebnisse konsistent mit denen von Demirer et al.

Die Darstellungsformen von Systemrelevanz in Betz et al. haben den Nachteil, dass kein grafisches Netzwerk oder keine numerische Kennzahl für einen Zeitraum zu Verfügung steht. Aufgrund der Betrachtung zum festen Zeitpunkt im Oktober 2008 stechen natürlich von der Krise besonders stark betroffenen Institute wie Dexia, Bank of Ireland und KBC vergleichsweise deutlich hervor. Dennoch sind bis auf die HSBC alle Top 10 SRS und SRR Institute in den 20 systemrelevantesten Banken nach Betz et al. enthalten.

Ein relevanter Unterschied zwischen den hier erhaltenen Ergebnissen und denen der Vergleichsansätze ist die Einschätzung der Systemrelevanz der Deutschen Bank, die anders als in dieser Arbeit in allen Vergleichsansätzen als systemrelevant eingestuft wird. Es gibt Gründe, die plausible Vermutungen darstellen, wieso die Deutsche Bank im hiesigen Ansatz nicht als systemrelevant eingestuft wird. So könnte z. B. die in den letzten Jahren durchgeführte Restrukturierung des Institutes seine Relevanz stark reduziert haben. Das Institut hat ganze Sparten an die Konkurrenz verkauft, darunter z. B. große Teile des elektronischen Aktienhandels und das Geschäft mit Hedgefonds (Handelsblatt 2019a). Auch Teile der Bilanz, die nicht mehr dem Kerngeschäft zuzuordnen sind wurden veräußert (Handelsblatt 2019b). Der hier untersuchte Datensatz enthält im Vergleich zu Demirer et al. drei weitere Jahre an Datenpunkten, die eine aus der Restrukturierung folgende sinkende Systemrelevanz aufnehmen könnten. Ein sinkender Trend ist auch aus den G-SIB-Listen zu erkennen: Die Deutsche Bank wurde seit 2012 zwei Mal vom Finanzstabilitätsrat in ihrer Systemrelevanz heruntergestuft. Ein anderer Grund könnten besonders starke Verbindungen der Deutschen Bank zu Instituten außerhalb des europäischen Bankensystems sein. Diese würden die Deutsche Bank bei globaler Betrachtung systemrelevant werden lassen, aufgrund der rein europäischen Betrachtung in dieser Arbeit jedoch nicht zur Geltung kommen. Demirer et al. untersuchen die Systemrelevanz anhand eines Datensatzes weltweiter Banken. Bei Betrachtung der Ergebnisse von Betz et al., die ebenfalls nur europäische Banken betrachten, befindet sich die Deutsche Bank auf Platz 19, was die hier erhaltenen Ergebnisse unterstützt. Um einen Schluss über die Systemrelevanz dieses Einzelinstitutes zu urteilen, bedarf es jedoch einer detaillierten Analyse interner Daten durch die Regulierungsbehörden.

Zusammenfassend kann gesagt werden, dass die hier angewandte Messung des CoVaRs beim Vergleich mit anderen Methoden der Messung von systemischen Risiken konsistente Ergebnisse liefert. Einzelne Abweichungen in den Ergebnissen sind dabei durch Unterschiede in den Methoden erklärbar.

6. Fazit

Die Finanzkrise 2008 hat gezeigt, dass nicht nur die Risiken auf Einzelinstitutsebene, sondern auch die Vernetzung eines Institutes im Gesamtsystem, bei der Betrachtung des Gesamtmarktrisikos berücksichtigt werden muss. Die Messung der Höhe des Vernetzungsgrades eines Institutes stellte dabei in der Vergangenheit eine Herausforderung dar. Mithilfe neuer Verfahrenstechniken verschiedener Autoren konnten diese innerhalb der letzten Jahre überwunden werden.

Diese Arbeit folgt dem Ansatz von Härdle et al. (2016) und identifiziert mittels zweistufigen Quantilregressionen mit Variablenerkennung Interdependenzen in den linken Enden der Renditeverteilungen von europäischen Finanzinstituten, um deren Systemrelevanz zu evaluieren. Die hierdurch erhaltene Höhe der Vernetzung von Einzelinstituten bestimmt das Aussehen des gesamten Netzwerkes europäischer Banken. In der verwendeten Methode gewährleistet das Lasso-Verfahren, dass nur relevante Interdependenzen betrachtet werden. Dies ermöglicht die Verwendung eines großen Datensatzes und eine somit detaillierte Analyse des europäischen Bankensystems. Die Systemrelevanz der Einzelinstitute wird über Indizes ermittelt, die von Instituten ausgehende und auf Institute eingehende Spillover sowie deren Marktkapitalisierung in Betracht ziehen.

Die erhaltenen Ergebnisse zeigen, dass das systemische Risiko im europäischen Bankensystem aufgrund weiter bestehender Unsicherheiten auch nach der Weltfinanzkrise hoch bleibt. Nationale Verbindungen zwischen Finanzinstituten weisen im europäischen System wegen ihrer Anzahl und Stärke einen besonders hohen Stellenwert auf. Jedoch sind überdurchschnittlich große Spillover-Effekte aus anderen Ländern vereinzelt beobachtbar. Dabei ist kein einzelnes Institut identifizierbar, das vermehrt Risiken emittiert. Lediglich die peripheren europäischen Staaten weisen als Gruppe ab 2013 im Vergleich zu Kerneuropa vermehrt ausgehende Spillover-Effekte auf. Das Netz europäischer Banken ist somit über eine Vielzahl kleiner und mittlerer Verbindungen definiert, wodurch kleinere Institute über deren Menge an Verbindungen systemrelevant werden können. Nichtsdestotrotz stellt sich heraus, dass Größe der treibende Faktor für die Systemrelevanz eines Institutes ist. Die von mittleren und kleineren Instituten ausgehenden Effekte auf große Institute sind nicht stark genug, um sie systemrelevant werden zu lassen. Die Ergebnisse der Einzelinstitutsebene können dabei in einem Vergleich mit den Ergebnissen anderer Methoden der systemischen Risikomessung verifiziert werden. Die Schnittmenge zwischen den in dieser Arbeit als systemrelevant identifizierten Institute und den durch die Kriterien der EBA identifizierten SIFIs, ist sehr hoch. Generell identifizieren alle Ansätze ähnliche

Institute, Abweichungen können dabei durch die Unterschiede in der Methodik erklärt werden. Die durch die Undurchsichtigkeit des EBA Ansatzes entstandene Sorge, dass falsche oder unzureichend viele Institutionen erkannt werden könnten, ist somit unbegründet.

Trotz ähnlicher Ergebnisse können die Indizes der systemischen Risiko Sender und systemischen Risiko Empfänger dabei helfen den Regulierungsprozess zu erweitern, indem sie einen Rahmen für die Quantifizierung des systemischen Risikos über öffentlich verfügbare Kapitalmarktdaten zu Verfügung stellen. Auf privater Information basierende Modelle wie der Scoring-Ansatz der EBA können nicht völlig durch einen marktbasierten Ansatz ersetzt werden, da durch private Informationen Spillover-Effekte aufgedeckt werden können, die auf Marktebene nicht sichtbar sind. Jedoch benötigt die Datenerhebung mehr Zeit, wodurch marktbasierte Ansätze durch schnelle Verfügbarkeit sowie Aktualität der Daten z. B. zu Überwachungszwecken sowie als erster Indikator dienen können, um Entscheidungen zu unterstützen. Wird ein Institut in dieser Methode hoch eingestuft, so sollte die Regulierung der Auffälligkeit nachgehen und auf Basis breiter Informationen Kapitalanforderungen festlegen (Betz et al. 2016).

Aufgrund fehlender Datenverfügbarkeit für die Schweizer Banken UBS und Credit Suisse fehlt die Einordnung zweier großer Institute in den europäischen Kontext. Zudem basiert das verwendete Verfahren auf öffentlichen Daten börsennotierter Banken. Relevante Institute bestimmter Länder könnten jedoch nicht börsennotiert sein. So besteht z. B. das deutsche Bankensystem aus einer Vielzahl nicht börsennotierter Institute wie Volksbanken und Sparkassen sowie deren Dachorganisationen. Eine Erweiterung des Datensatzes oder der Methode, die die Untersuchung dieser Institute ermöglicht, wäre wünschenswert, um alle potenziell systemrelevanten Institute in der Untersuchung abzudecken und alle nationalen Bankensysteme adäquat darzustellen.

III. Literaturverzeichnis

- Acharya, Viral; Drechsler, Itamar; Schnabl, Philipp** (2014): A Pyrrhic Victory? Bank Bailouts and Sovereign Credit Risk. In: *The Journal of Finance* 69 (6), S. 2689–2739. DOI: 10.1111/jofi.12206.
- Acharya, Viral; Pedersen, Lasse H.; Philippon, Thomas; Richardson, Matthew** (2017): Measuring Systemic Risk. In: *The Review of Financial Studies* 30 (1), S. 2–47. DOI: 10.1093/rfs/hhw088.
- Adamic, Lada; Brunetti, Celso; Harris, Jeffrey H.; Kirilenko, Andrei** (2009): On the Informational Properties of Trading Networks. Manuskript, University of Michigan.
- Adamic, Lada; Brunetti, Celso; Harris, Jeffrey H.; Kirilenko, Andrei** (2017): Trading Networks. In: *The Econometrics Journal* 20 (3), 126–149. DOI: 10.1111/ectj.12090.
- Adrian, Tobias; Brunnermeier, Markus K.** (2016): CoVaR. In: *American Economic Review* 106 (7), S. 1705–1741. DOI: 10.1257/aer.20120555.
- Adrian, Tobias; Etula, Erkki; Muir, Tyler** (2014): Financial Intermediaries and the Cross-Section of Asset Returns. In: *The Journal of Finance* 69 (6), S. 2557–2596. DOI: 10.1111/jofi.12189.
- Adrian, Tobias; Shin, Hyun Song** (2010): Liquidity and Leverage. In: *Journal of Financial Intermediation* 19 (3), S. 418–437. DOI: 10.1016/j.jfi.2008.12.002.
- Albertazzi, Ugo; Gambacorta, Leonardo** (2009): Bank Profitability and the Business Cycle. In: *Journal of Financial Stability* 5 (4), S. 393–409. DOI: 10.1016/j.jfs.2008.10.002.
- Allen, Franklin; Gale, Douglas** (2000): Financial Contagion. In: *Journal of Political Economy* 108 (1), S. 1–33. DOI: 10.1086/262109.
- Battiston, Stefano; Delli Gatti, Domenico; Gallegati, Mauro; Greenwald, Bruce; Stiglitz, Joseph E.** (2012): Liaisons Dangereuses: Increasing Connectivity, Risk Sharing and Systemic risk. In: *Journal of Economic Dynamics and Control* 36 (8), S. 1121–1141. DOI: 10.1016/j.jedc.2012.04.001.
- Belloni, Alexandre; Chernozhukov, Victor** (2011): ℓ_1 -penalized Quantile Regression in High-Dimensional Sparse Models. In: *Annals of Statistics* 39 (1), S. 82–130. DOI: 10.1214/10-AOS827.
- Betz, Frank; Hautsch, Nikolaus; Peltonen, Tuomas A.; Schienle, Melanie** (2016): Systemic Risk Spillovers in the European Banking and Sovereign Network. In: *Journal of Financial Stability* 25, S. 206–224. DOI: 10.1016/j.jfs.2015.10.006.
- Billio, Monica; Getmansky, Mila; Lo, Andrew W.; Pelizzon, Lorian** (2012): Econometric Measures of Connectedness and Systemic Risk in the Finance and Insurance Sectors. In: *Journal of Financial Economics* 104 (3), S. 535–559. DOI: 10.1016/j.jfineco.2011.12.010.
- Bisias, Dimitrios; Flood, Mark; Lo, Andrew W.; Valavanis, Stavros** (2012): A Survey of Systemic Risk Analytics. In: *Annual Review of Financial Economics* 4 (1), S. 255–296. DOI: 10.1146/annurev-financial-110311-101754.
- Borio, Claudio E. V.** (2004): Market Distress and Vanishing Liquidity: Anatomy and Policy Options. In: *BIS Working Papers* (158). DOI: 10.2139/ssrn.781228.
- Brownlees, Christian; Engle, Robert F.** (2017): SRISK: A Conditional Capital Shortfall Measure of Systemic Risk. In: *Review of Financial Studies* 30 (1), S. 48–79. DOI: 10.1093/rfs/hhw060.
- Brunnermeier, Markus K.; Oehmke, Martin** (2013): The Maturity Rat Race. In: *The Journal of Finance* 68 (2), S. 483–521. DOI: 10.1111/jofi.12005.
- Brunnermeier, Markus K.; Pedersen, Lasse Heje** (2009): Market Liquidity and Funding Liquidity. In: *Review of Financial Studies* 22 (6), S. 2201–2238. DOI: 10.1093/rfs/hhn098.

Buraschi, Andrea; Porchia, Paolo; Trojani, Fabio (2010): The Cross-Section of Expected Stock Returns: Learning about Distress and Predictability in Heterogeneous Orchards. In: *AFA 2011 Denver Meetings Paper*. DOI: 10.2139/ssrn.1573015.

Cameron, Adrian Colin; Trivedi, Pravin K. (2005): *Microeconometrics. Methods and Applications*. New York: Cambridge University Press.

Danielsson, Jon; Shin, Hyun Song; Zigrand, Jean-Pierre (2011): Balance Sheet Capacity and Endogenous Risk. In: *FMG Discussion Paper Series* (665). Online verfügbar unter <http://e-prints.lse.ac.uk/43141/>, zuletzt geprüft am 02.10.2020.

Demirer, Mert; Diebold, Francis X.; Liu, Laura; Yilmaz, Kamil (2018): Estimating Global Bank Network Connectedness. In: *Journal of Applied Econometrics* 33 (1), S. 1–15. DOI: 10.1002/jae.2585.

Dexia (2009): Annual Report 2009. Online verfügbar unter <https://www.dexia.com/sites/default/files/2019-12/DSA%20Annual%20Report%202009%20EN.pdf>, zuletzt geprüft am 20.09.2020.

Dexia (2011): Annual Report 2011. Online verfügbar unter https://www.dexia.com/sites/default/files/2019-12/DSA%20Annual%20Report%202011%20EN_0.pdf, zuletzt geprüft am 20.09.2020.

Diebold, Francis X.; Yilmaz, Kamil (2009): Measuring Financial Asset Return and Volatility Spillovers, with Application to Global Equity Markets. In: *The Economic Journal* 119 (534), S. 158–171. DOI: 10.1111/j.1468-0297.2008.02208.x.

Diebold, Francis X.; Yilmaz, Kamil (2012): Better to Give Than to Receive: Predictive Directional Measurement of Volatility Spillovers. In: *International Journal of Forecasting* 28 (1), S. 57–66. DOI: 10.1016/j.ijforecast.2011.02.006.

Diebold, Francis X.; Yilmaz, Kamil (2015): Trans-Atlantic Equity Volatility Connectedness: U.S. and European Financial Institutions, 2004–2014. In: *Journal of Financial Econometrics* 14 (1), 81–127. DOI: 10.1093/jjfinec/nbv021.

Diebold, Francis X.; Yilmaz, Kamil (2014): On the Network Topology of Variance Decompositions: Measuring the Connectedness of Financial Firms. In: *Journal of Econometrics* 182 (1), S. 119–134. DOI: 10.1016/j.jeconom.2014.04.012.

EBA (2016): Final draft Implementing Technical Standards Amending the Commission Implementing Regulation (EU) No 1030/2014 On the Uniform Formats and Date for the Disclosure of the Values Used to Identify Global Systemically Important Institutions. EBA/ITS/2016/01. Online verfügbar unter [https://eba.europa.eu/sites/default/documents/files/documents/10180/1333778/fcfd8df8-deff-4350-9c8c-d17cb27c54c5/EBA-ITS-2016-01%20\(Final%20draft%20ITS%20on%20G-SII%20identification\).pdf](https://eba.europa.eu/sites/default/documents/files/documents/10180/1333778/fcfd8df8-deff-4350-9c8c-d17cb27c54c5/EBA-ITS-2016-01%20(Final%20draft%20ITS%20on%20G-SII%20identification).pdf), zuletzt geprüft am 07.08.2020.

Elyasiani, Elyas; Hasan, Iftekhar; Kalotychou, Elena; Pouliasis, Panos K.; Staikouras, Sotiris K. (2020): Banks' Equity Performance and the Term Structure of Interest Rates. In: *Financial Markets, Institutions & Instruments* 29 (2), S. 43–64. DOI: 10.1111/fmii.12125.

Europäische Union (2013): Richtlinie 2013/36/EU des europäischen Parlaments und des Rates vom 26. Juni 2013 über den Zugang zur Tätigkeit von Kreditinstituten und die Beaufsichtigung von Kreditinstituten und Wertpapierfirmen, zur Änderung der Richtlinie 2002/87/EG und zur Aufhebung der Richtlinien 2006/48/EG und 2006/49/EG. Richtlinie 2013/36/EU, vom 09.07.2018 (L 176/338).

Europäische Union (2014): Delegierten Verordnung (EU) Nr. 1222/2014 der Kommission vom 8. Oktober 2014 zur Ergänzung der Richtlinie 2013/36/EU des Europäischen Parlaments und des Rates durch technische Regulierungsstandards zur Festlegung der Methode zur Bestimmung global systemrelevanter Institute und zur Festlegung der Teilkategorien global systemrelevanter Institute. Delegierten Verordnung (EU) Nr. 1222/2014, vom 09.09.2016 (L 330/27).

- Europäische Zentralbank** (2000): Asset Prices and Banking Stability. Frankfurt am Main: Europ. Central Bank.
- Fan, Jianqing; Li, Runze** (2011): Variable Selection via Nonconcave Penalized Likelihood and its Oracle Properties. *Journal of the American Statistical Association* 96 (456), S. 1348–1360. DOI: 10.1198/016214501753382273.
- Farhi, Emmanuel; Tirole, Jean** (2012): Collective Moral Hazard, Maturity Mismatch, and Systemic Bailouts. In: *American Economic Review* 102 (1), S. 60–93. DOI: 10.1257/aer.102.1.60.
- Freixas, Xavier; Parigi, Bruno M.; Rochet, Jean-Charles** (2000): Systemic Risk, Interbank Relations, and Liquidity Provision by the Central Bank. In: *Journal of Money, Credit and Banking* 32 (3), S. 611. DOI: 10.2307/2601198.
- Furfine, Craig H.** (2003): Interbank Exposures: Quantifying the Risk of Contagion. In: *Journal of Money, Credit and Banking* 35 (1), S. 111–128. Online verfügbar unter <https://www.jstor.org/stable/3649847>, zuletzt geprüft am 07.08.2020.
- Galvez, Julio; Mencia, Javier** (2014): Distributional Linkages between European Sovereign Bond and Bank Asset Returns. In: *SSRN Journal*. DOI: 10.2139/ssrn.2523863.
- Giesecke, Kay; Kim, Baeho** (2011): Systemic Risk: What Defaults Are Telling Us. In: *Management Science* 57 (8), S. 1387–1405. DOI: 10.1287/mnsc.1110.1375.
- Gorton, Gary; Metrick, Andrew** (2012): Securitized Banking and the Run on Repo. In: *Journal of Financial Economics* 104 (3), S. 425–451. DOI: 10.1016/j.jfineco.2011.03.016.
- Handelsblatt** (2019a): Deutsche Bank verkauft Geschäft mit Hedgefonds an BNP Paribas. Frankfurt. Online verfügbar unter <https://www.handelsblatt.com/finanzen/banken-versicherungen/konzernumbau-deutsche-bank-verkauft-geschaef-mit-hedgefonds-an-bnp-paribas/25044350.html?ticket=ST-2468959-xdxFumsgMCMxgRDklQcJ-ap4>, zuletzt geprüft am 05.10.2020.
- Handelsblatt** (2019b): Deutsche Bank verkauft 50-Milliarden-Dollar-Portfolio an Goldman Sachs. Frankfurt. Online verfügbar unter <https://www.handelsblatt.com/finanzen/banken-versicherungen/abbaueinheit-deutsche-bank-verkauft-50-milliarden-dollar-portfolio-an-goldman-sachs/25275266.html>, zuletzt geprüft am 05.10.2020.
- Härdle, Wolfgang Karl; Wang, Weining; Yu, Lining** (2016): TENET: Tail-Event Driven NETWORK Risk. In: *Journal of Econometrics* 192 (2), S. 499–513. DOI: 10.1016/j.jeconom.2016.02.013.
- Hartmann-Wendels, Thomas; Pfingsten, Andreas; Weber, Martin** (2019): Bankbetriebslehre. 7. Auflage. Berlin: Springer (Lehrbuch).
- Harvey, Andrew; Lange, Rutger-Jan** (2018): Modeling the Interactions Between Volatility and Returns Using EGARCH-M. In: *Journal of Time Series Analysis* 39 (6), S. 909–919. DOI: 10.1111/jtsa.12419.
- Hautsch, N.; Schaumburg, J.; Schienle, M.** (2015): Financial Network Systemic Risk Contributions. In: *European Economic Review* 19 (2), S. 685–738. DOI: 10.1093/rof/rfu010.
- Heinz, Frigyes; Sun, Yan** (2014): Sovereign CDS Spreads in Europe. The Role of Global Risk Aversion, Economic Fundamentals, Liquidity, and Spillovers. In: *IMF Working Paper* (17). Online verfügbar unter <http://elibrary.imf.org/view/IMF001/21116-9781484393017/21116-9781484393017/21116-9781484393017.xml>.
- Huang, Xin; Zhou, Hao; Zhu, Haibin** (2009): A Framework for Assessing the Systemic Risk of Major Financial Institutions. In: *Journal of Banking & Finance* 33 (11), S. 2036–2049. DOI: 10.1016/j.jbankfin.2009.05.017.

- Jordan, Dan J.; Rice, Douglas; Sanchez, Jacques; Wort, Donald H.** (2011): Explaining Bank Market-to-Book Ratios: Evidence From 2006 to 2009. In: *Journal of Banking & Finance* 35 (8), S. 2047–2055. DOI: 10.1016/j.jbankfin.2011.01.017.
- Koenker, Roger** (2005): Quantile Regression. Cambridge: Cambridge University Press.
- Koenker, Roger; Bassett, Gilbert** (1978): Regression Quantiles. In: *Econometrica* 46 (1), S. 33–50. DOI: 10.2307/1913643.
- Koetter, Michael; Poghosyan, Tigran** (2010): Real Estate Prices and Bank Stability. *Journal of Banking & Finance*, 34(6), 1129–1138. DOI: 10.1016/J.JBANK-FIN.2009.11.010.
- Koopman, Siem Jan; Lucas, André; Schwaab, Bernd** (2011): Modeling Frailty-Correlated Defaults Using Many Macroeconomic Covariates. In: *Journal of Econometrics* 162 (2), S. 312–325. DOI: 10.1016/j.jeconom.2011.02.003.
- Krishnamurthy, Arvind** (2010): Amplification Mechanisms in Liquidity Crises. In: *American Economic Journal: Macroeconomics* 2 (3), S. 1–30. DOI: 10.1257/mac.2.3.1.
- Lehar, Alfred** (2005): Measuring Systemic Risk: A risk Management Approach. In: *Journal of Banking & Finance* 29 (10), S. 2577–2603. DOI: 10.1016/j.jbankfin.2004.09.007.
- Leitner, Yaron** (2005): Financial Networks: Contagion, Commitment, and Private Sector Bailouts. In: *The Journal of Finance* 60 (6), S. 2925–2953. DOI: 10.1111/j.1540-6261.2005.00821.x.
- Li, Qi; Yang, Jian; Hsiao, Cheng; Chang, Young-Jae** (2005): The Relationship Between Stock Returns and Volatility in International Stock Markets. In: *Journal of Empirical Finance* 12 (5), S. 650–665. DOI: 10.1016/j.jempfin.2005.03.001.
- Linzert, Tobias; Schmidt, Sandra** (2011): What Explains the Spread Between the Euro Overnight Rate and the ECB's Policy Rate? In: *International Journal of Finance & Economics* 16 (3), S. 275–289. DOI: 10.1002/ijfe.430.
- Lo Duca, Marco; Koban, Anne; Basten, Marisa; Bengtsson, Elias; Klaus, Benjamin; Kusmierczyk, Piotr; Lang, Jan Hannes** (2017): A New Database for Financial Crises in European Countries. ECB/ESRB EU crises database. In: *European Central Bank Occasional Paper Serie* (194). Online verfügbar unter <https://www.ecb.europa.eu/pub/pdf/scpops/ecb.op194.en.pdf>, zuletzt geprüft am 07.08.2020.
- McQuarrie, Allan D. R.; Tsai, Chih-Ling** (1998): Regression and Time Series Model Selection: World Scientific.
- Mihoci, Andrija; Althof, Michael; Chen, Cathy Yi-Hsuan; Härdle, Wolfgang K.** (2019): FRM Financial Risk Meter. In: *Advances in Econometrics* (42).
- Minsky, Hyman** (1977): A Theory of Systemic Fragility. In: E. D. Altman und A. W. Sametz (Hg.): *Financial Crises: Institutions and Markets in a Fragile Environment*. New York: John Wiley and Sons, S. 138–152.
- Moody's** (2012): Key Drivers of Italian Bank Rating Actions. Online verfügbar unter https://www.moody's.com/researchdocumentcontentpage.aspx?docid=PBC_141195, zuletzt aktualisiert am 20.09.2020, zuletzt geprüft am 20.09.2020.
- Panetta, Fabio** (2011): The Impact of Sovereign Credit Risk on Bank Funding Conditions. In: *CGFS Papers* (43). Online verfügbar unter <https://www.bis.org/publ/cgfs43.pdf>, zuletzt geprüft am 01.10.2020.

Reuters (2012): S&P Downgrades 34 Italian Banks. Online verfügbar unter <https://de.reuters.com/article/italy-banks-idINDEE8190J120120210>, zuletzt aktualisiert am 20.09.2020, zuletzt geprüft am 20.09.2020.

Rodríguez-Moreno, María; Peña, Juan Ignacio (2013): Systemic Risk Measures: The Simpler the Better? In: *Journal of Banking & Finance* 37 (6), S. 1817–1831. DOI: 10.1016/j.jbankfin.2012.07.010.

S&P Global Market Intelligence (2020): CET1 Capital Ratios at Europe's Largest Banks, Q4. Unter Mitarbeit von Peter Murphy, Francis Garrido und Rehan Ahmad. S&P Global Market Intelligence. Online verfügbar unter <https://www.spglobal.com/marketintelligence/en/news-insights/latest-news-headlines/cet1-capital-ratios-at-europe-s-largest-banks-q4-57567429>, zuletzt geprüft am 08.09.2020.

Schwaab, Bernd; Koopman, Siem Jan; Lucas, André (2011): Systemic Risk Diagnostics: Coincident Indicators and Early Warning Signals. In: *ECB Working Paper* (1327). Online verfügbar unter <https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp1327.pdf>, zuletzt geprüft am 08.08.2020.

Segoviano Basurto, Miguel; Goodhart, Charles A.E. (2009): Banking Stability Measures. In: *IMF Working Paper* (4). Online verfügbar unter <https://www.imf.org/external/pubs/ft/wp/2009/wp0904.pdf>, zuletzt geprüft am 08.08.2020.

Shao, Jun (1993): Linear Model Selection by Cross-Validation. In: *Journal of the American Statistical Association* 88 (422), S. 486–494. DOI: 10.2307/2290328.

Shao, Jun (1997): An Asymptotic Theory for Linear Model Selection. In: *Statistica Sinica* 7 (2), S. 221–242. Online verfügbar unter <https://www.jstor.org/stable/24306073>, zuletzt geprüft am 01.10.2020.

Stoxx (2020): Stoxx Strategy Index Guide. Creating an Investment Intelligence Advantage. Hg. v. Stoxx. Online verfügbar unter https://www.stoxx.com/document/Indices/Common/Indexguide/stoxx_strategy_guide.pdf, zuletzt geprüft am 09.09.2020.

Tarashev, Nikola A.; Borio, Claudio E. V.; Tsatsaronis, Kostas (2009): The Systemic Importance of Financial Institutions. In: *BIS Quarterly Review* (September 2009). Online verfügbar unter https://www.bis.org/publ/qtrpdf/r_qt0909h.pdf?noframes=1, zuletzt geprüft am 01.10.2020.

Tibshirani, Robert (1996): Regression Shrinkage and Selection via the Lasso. In: *Journal of the Royal Statistical Society* 58 (1), S. 267–288. Online verfügbar unter <http://www.jstor.org/stable/2346178>.

Upper, Christian; Worms, Andreas (2004): Estimating Bilateral Exposures in the German Interbank Market: Is There a Danger of Contagion? In: *European Economic Review* 48 (4), S. 827–849. DOI: 10.1016/j.eurocorev.2003.12.009.

Wang, Hansheng; Li, Runze; Tsai, Chih-Ling (2007): Tuning Parameter Selectors for the Smoothly Clipped Absolute Deviation Method. In: *Biometrika* 94 (3), S. 553–568. DOI: 10.1093/biomet/asm053.

Welfens, Paul J. J.; Kadiric, Samir (2018): Bankenaufsicht, unkonventionelle Geldpolitik und Bankenregulierung. Berlin, Boston: De Gruyter.

Yang, Yuhong (2005): Can the Strengths of AIC and BIC Be Shared? A Conflict Between Model Identification and Regression Estimation. *Biometrika* 92 (4), S. 937–950. DOI: 10.1093/BIOMET/92.4.937.

Yu, Lining; Härdle, Wolfgang Karl; Borke, Lukas; Benschop, Thijs (2017): FRM: A Financial Risk Meter Based on Penalizing Tail Events Occurrence. In: *SFB Discussion Paper* (003). DOI: 10.2139/ssrn.2919263.

Zheng, Qi; Gallagher, Colin; Kulasekera, K. B. (2013): Adaptive Penalized Quantile Regression for High Dimensional Data. In: *Journal of Statistical Planning and Inference* 143 (6), S. 1029–1038. DOI: 10.1016/j.jspi.2012.12.009.

Zhou, Chen (2009): Are Banks Too Big To Fail? Measuring Systemic Importance of Financial Institutions. In: *SSRN Journal*. DOI: 10.2139/ssrn.1546384.

Zou, Hui (2006): The Adaptive Lasso and Its Oracle Properties. In: *Journal of the American Statistical Association* 101 (476), S. 1418–1429. DOI: 10.1198/016214506000000735.

Eidesstattliche Erklärung

Ich erkläre hiermit an Eides statt, dass ich meine Masterarbeit

„Systemisches Risiko im europäischen Bankensystem“

selbstständig und ohne fremde Hilfe angefertigt habe und dass ich alle von anderen Autoren wörtlich übernommenen Stellen wie auch die sich an die Gedankengänge anderer Autoren eng anlehnenden Ausführungen meiner Arbeit besonders gekennzeichnet und die entsprechenden Quellen zitiert habe. Die Arbeit wurde bisher weder gesamt noch in Teilen einer anderen Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Münster, 07. Oktober 2020

Dirk Laschat

Einverständniserklärung zur Plagiatsprüfung

Name: Laschat

Vorname: Dirk

Matrikelnummer: 430765

Studiengang: Master of Economics

Adresse: Bismarckallee 49 (C104), 48151 Münster, Deutschland

Titel der Arbeit: Systemisches Risiko im europäischen Bankensystem

Was ist ein Plagiat?

Als ein Plagiat wird eine Übernahme fremden Gedankengutes in die eigene Arbeit angesehen, bei der die Quelle, aus der die Übernahme erfolgt, nicht kenntlich gemacht wird. Es ist dabei unerheblich, ob z.B. fremde Texte wörtlich übernommen werden, nur Strukturen (z.B. argumentative Figuren oder Gliederungen) aus fremden Quellen entlehnt oder Texte aus einer Fremdsprache übersetzt werden.

Softwarebasierte Überprüfung

Alle Bachelor- und Masterarbeiten werden vom Prüfungsamt mit Hilfe einer entsprechenden Software auf Plagiate geprüft. Die Arbeit wird zum Zweck der Plagiatsüberprüfung an einen Software- Dienstleister übermittelt und dort auf Übereinstimmung mit anderen Quellen geprüft. Zum Zweck eines zukünftigen Abgleichs mit anderen Arbeiten wird die Arbeit dauerhaft in einer Datenbank gespeichert. Ein Abruf der Arbeit ist ausschließlich durch die Wirtschaftswissenschaftliche Fakultät der Westfälischen Wilhelms-Universität Münster möglich. Der Studierende erklärt sich damit einverstanden, dass allein zum beschriebenen Zweck der Plagiatsprüfung die Arbeit dauerhaft gespeichert und vervielfältigt werden darf. Das Ergebnis der elektronischen Plagiatsprüfung wird dem Erstgutachter mitgeteilt.

Sanktionen

Liegt ein Plagiat vor, ist dies ein Täuschungsversuch i.S. der Prüfungsordnung, durch den die Prüfungsleistung als „nicht bestanden“ gewertet wird. Es erfolgt eine Mitteilung an das Prüfungsamt und die dortige Dokumentation. In schwerwiegenden Täuschungsfällen kann der Prüfling von der Prüfung insgesamt ausgeschlossen werden. Dies kann unter Umständen die Exmatrikulation bedeuten. Plagiate können auch nach Abschluss des Prüfungsverfahrens und Verleihung des Hochschulgrades zum Entzug des erworbenen Grades führen.

Hiermit erkläre ich, dass ich die obigen Ausführungen gelesen habe und mit dem Verfahren zur Aufdeckung und Sanktionierung von Plagiaten einverstanden bin.

Münster, 07. Oktober 2020

Unterschrift des Studierenden